



Oscar Toledo Fernandez | Izan Rodríguez García

SIS2B



Índice

Introducción	3
Homelab	4
Introducción	4
Diagrama de red y contenerización	5
VPN	7
Pi-Hole	10
Galería Immich	15
Fail2ban	28
Uptime Kuma	30
Netdata	35
n8n	39
IA en local (PC)	46
Antes de empezar	47
Instalación de Ollama, verificación del servicio, Descarga del modelo.	48
Descarga de modelos (LLM)	49
Instalación de docker, Despliegue de Open WebUI, Configuración inicial	50
Configuración Inicial y primer chat	52
Exposición de Ollama a la Red	55
Integración Final en OpenWebUI	56
Funcionalidades	57
Monitorización en IA	61
Raspberry PI + HAT AI	63
Instalación de Sistema Operativo	64
Instalación de dependencias y ollama	77
Instalación de openclaw	80
OpenWebUI	85
Analizador Video AI	87
NVIDIA SPARK	93
Instalación de OpenWebUI	94
Framework AI starter Kit for Jetson Orin Nano	98
Nvidia Jetson Orin Nano	99
Comparación entre Hardwares	106
Tabla de comparación	106
NVIDIA 4060 Ti 16GB	107
Raspberry Pi HAT AI2+	107
NVIDIA SPARK	108
NVIDIA JETSON ORIN NANO	108
Consumos de energía y tokens	109
3 Tipos de RAM y Crisis	110
Ingeniería de Prompt	113
Partes no completadas y Expansiones	116
Conclusiones	117
Web/Bibliografía	118



Introducción

Novacreux es un ecosistema tecnológico diseñado para empresas y profesionales que buscan explorar nuevas profundidades en la innovación digital. Nuestra misión es llenar el vacío existente entre las capacidades de la inteligencia artificial de vanguardia, la seguridad robusta y la agilidad de los cyberdecks, ofreciendo soluciones modulares, potentes y flexibles que se adaptan a los desafíos del futuro.

El proyecto está dividido en varios bloques principales, los siguientes, homelab, IA en local en casa con gráfica gaming, IA en Raspberry, NVIDIA JETSON ORIN NANO, NVIDIA SPARK.

En el homelab (ubicado en mi domicilio) veremos cómo gestionar varios servicios en contenedores docker, que tanto en casa como en una empresa, pueden ser útiles.

En la IA en local de casa, veremos cómo desde un PC de usuario normal con gráfica dedicada (también ubicado en mi domicilio), podemos ejecutar un modelo de IA generativa capaz de generar texto, leer fotos, pdfs y más formatos, aplicando medidas preventivas de seguridad con permisos y usuarios.

Con la Raspberry hemos podido realizar un análisis de video pregrabado, el cual en un entorno real podría salvar vidas y evitar muchas multas a empresas, u otros muchos usos.

Con la NVIDIA Spark hemos podido realizar el mismo proyecto que con la IA en casa, pero usando un hardware más potente y compararemos los resultados de ambas plataformas.

Con la NVIDIA JETSON ORIN NANO, junto a un kit de desarrollo con forma de maletín, se ha podido probar levemente cómo gracias a agentes de IA, se puede controlar sensores y actuar sobre ellos a consecuencia de los datos que nos proporciona de manera automática.

Al final cómo resultado, nos da que cada apartado de este proyecto són perfectamente extrapolables a una empresa o entorno de trabajo, el cual evita pérdidas humanas o materiales, mejora la seguridad en cada paso y actuando antes y mejor, incluso autónomamente, además de incrementar la productividad y mejorar el ecosistema propio de la empresa sin depender de altos costes en servicios externos y disminuyendo la superficie de ataque.



Homelab

Introducción

Detrás de una IA en local existe toda una infraestructura útil para poder hacer que esta no se quede únicamente en tu propio PC, por lo que sobre un PC antiguo montamos algunas herramientas y servicios de utilidad.

Sobre este Server tenemos montados una VPN, una galería como Google Fotos , sistemas de monitorización o un servicio DNS propio.

En las siguientes páginas detallaremos para qué estamos usando cada servicio, su funcionalidad, cómo instalarlo.

El homelab se monta sobre Ubuntu Server sin GUI como OS y el siguiente hardware:

	Homelab Izan
CPU:	Intel i7-4790
RAM:	4x 4GB DDR3
Disco duro	436GB SSD Kingston

La IA generativa a día de hoy es una herramienta indispensable para nuestro día a día y el de una empresa, por lo que consideramos muy importante saber montar y gestionar un servicio como este en casi cualquier entorno. Es importante que nuestros datos sean 100% privados y totalmente accesible por personas de nuestra confianza, por lo que tener nuestra IA en un entorno cerrado y local es indispensable.

Después de explicar el entorno homelab se detalla la IA en local (página 41).

Sobre el homelab y la IA en local hay mas información en

<https://izan1706.github.io>






```
izanserver@izanserver:~$ neofetch

.-/+0oosssso+/-.
':+ssssssssssssssss+:`
--+ssssssssssssssssyyssst+
.osssssssssssssssssdMMMMyssso.
/ssssoosssssshdmmNNmmymMMMMhssssso/
+ssssssssshmydMMMMMMMMNdddyssssssst+
/ssssoosssssshNMMMyhyhyymNMMMNhssssssso/
.ssssssssdMMMNhssssssssshNMMMdssssssso.
+ssssshhhyNMMMysssssssssssyNMMMyssssssst+
ossyNMMMNyMMhssssssssssshmmhssssssso
ossyNMMMNyMMhssssssssssshmmhssssssso
+ssssshhhyNMMMysssssssssssyNMMMyssssssst+
.ssssssssdMMMNhssssssssshNMMMdssssssso.
/ssssoosssssshNMMMyhyhyymNMMMNhssssssso/
+sssssssssdmydMMMMMMMMNdddyssssssst+
/ssssoosssssshdmmNNmmymMMMMhssssso/
.osssssssssssssssssdMMMMyssso.
--+ssssssssssssssssyyssst+
':+ssssssssssssssss+:`
.-/+0oosssso+/-.

izanserver@izanserver
-----
OS: Ubuntu 24.04.1 LTS x86_64
Host: OptiPlex 7020 01
Kernel: 6.8.0-110-generic
Uptime: 5 days, 14 hours, 22 mins
Packages: 874 (dpkg)
Shell: bash 5.2.21
Terminal: /dev/pts/0
CPU: Intel i7-4790 (8) @ 4.000GHz
GPU: Intel HD Graphics
Memory: 2184MiB / 15897MiB
```

Diagrama de red y contenerización

Aunque en nuestro caso este diagrama de red sea muy sencillo y sin ninguna configuración de VLAN o otros servicios es indispensable para la comunicación de cualquier dispositivo, la siguiente imagen muestra la topología de red física:



```
izanserver@izanserver:~$ ip a
1: lo: <LOOPBACK,UP,LOWER_UP> mtu 65536 qdisc noqueue state UNKNOWN group default qlen 1
    link/loopback 00:00:00:00:00:00 brd 00:00:00:00:00:00
    inet 127.0.0.1/8 scope host lo
        valid_lft forever preferred_lft forever
    inet6 ::1/128 scope host noprefixroute
        valid_lft forever preferred_lft forever
2: eno1: <BROADCAST,MULTICAST,UP,LOWER_UP> mtu 1500 qdisc pfifo_fast state UP group default qlen 1000
    link/ether 98:90:96:ca:9e:df brd ff:ff:ff:ff:ff:ff
    altname enp0s25
    inet 192.168.1.24 metric 100 brd 192.168.1.255 scope global eno1
        valid_lft forever preferred_lft forever
    inet6 fe80::9a90:96ff:feca:9edf/64 scope link
        valid_lft forever preferred_lft forever
3: tailscale0: <POINTOPOINT,MULTICAST,NOARP,UP,LOWER_UP> mtu 1280 qdisc pfifo_fast state UP group default qlen 1000
    link/native
    inet 10.0.0.32 scope global tailscale0
        valid_lft forever preferred_lft forever
    inet6 fd7a:115c:a1e0:bd39:7655/128 scope global
        valid_lft forever preferred_lft forever
    inet6 fe80::c5d7:b71b:baae:c322/64 scope link stable-privacy
        valid_lft forever preferred_lft forever
4: br-7f5960025fc3: <BROADCAST,MULTICAST,UP,LOWER_UP> mtu 1500 qdisc noqueue state UP group default qlen 1000
    link/ether 3a:fb:42:dd:7a:44 brd ff:ff:ff:ff:ff:ff
    inet 172.19.0.1/16 brd 172.19.255.255 scope global br-7f5960025fc3
        valid_lft forever preferred_lft forever
    inet6 fe80::38fb:42ff:fedd:7a44/64 scope link
        valid_lft forever preferred_lft forever
```




Sobre el homelab que contiene un Ubuntu Server sin GUI, con el fin de compartimentar y aplicarle una capa más de seguridad se está usando la tecnología Docker para segmentar los servicios. Gracias a este servicio podemos implementar las librerías correctas cuando se necesitan sin conflictos con otras instancias las cuales necesitan otras, además de si un servicio genera un error los demás siguen funcionando sin importar el error.

```
izanserver@izanserver:~$ sudo docker ps
[sudo] password for izanserver:
CONTAINER ID   IMAGE                                COMMAND                  CREATED        STATUS        PORTS
NAMES
f5117f231265   n8nio/n8n:latest                    "tini -- /docker-ent..." 20 hours ago   Up 20 hours   0.0.0.0:5678->5678/tcp, [::]:5678->5678/tcp
n8n-n8n-1
dcc9634368df   ghcr.io/immich-app/immich-server:v2 "tini -- /bin/bash -..." 2 weeks ago    Up 20 hours (healthy) 0.0.0.0:2283->2283/tcp, [::]:2283->2283/tcp
immich_server
894fff69b7fa   ghcr.io/immich-app/postgres:14-vectorchord0.4.3-pgvector0.2.0 "/usr/local/bin/immich..." 2 weeks ago    Up 20 hours (healthy) 5432/tcp
immich_postgres
4eab9ca1378f   ghcr.io/immich-app/immich-machine-learning:v2 "tini -- python -m i..." 2 weeks ago    Up 20 hours (healthy)
immich_machine_learning
ade62a538dbc   valkey/valkey:9                     "docker-entrypoint.s..." 2 weeks ago    Up 20 hours (healthy) 6379/tcp
immich_redis
483d17ac7878   ghcr.io/gethomepage/homepage:latest "docker-entrypoint.s..." 3 weeks ago     Up 20 hours (healthy) 0.0.0.0:8080->3000/tcp, [::]:8080->3000/tcp
homepage
izanserver@izanserver:~$
```





VPN



La VPN es un punto muy importante a la hora de usar un servicio de manera segura y de manera remota sin exponer datos, evitando posibles brechas de seguridad, por lo que se ha montado una solución VPN, para usar otros servicios menos comunes que Wireguard o similares, se ha decidido usar Tailscale, esta plataforma permite conectarte desde prácticamente cualquier dispositivo (ahora en uso desde Ubuntu Server, Windows, Android), su configuración es más básica, ya que únicamente se ha de instalar y adherir una cuenta de correo. Una posible mejora en este punto es usar Wireguard, de esta manera asegurarnos de que corre 100% en local, sin servicios externos.

Esta herramienta contiene un *Dashboard* de administración, el cual te menciona que equipos hay, que equipos están conectados y te muestra su IP, así, por ejemplo, poder conectarse con un SSH a ellas.

En la siguiente captura se muestra la información básica de la VPN, se censuran las IPs que te asigna Tailscale, ya que forman parte de mi red privada.



The screenshot shows the Tailscale dashboard for the user izanro06@gmail.com. The 'Machines' tab is selected, displaying a list of 4 machines. The table columns are MACHINE, ADDRESSES, VERSION, and LAST SEEN. The machines listed are desktop-3ok5ts6 (Windows 11 25H2), izan (Linux 6.17.0-19-generic), izanserver (Linux 6.8.0-106-generic), and redmi-note-13-5g (Android 15). The IP addresses are redacted with red boxes.

MACHINE	ADDRESSES	VERSION	LAST SEEN
desktop-3ok5ts6 izanro06@gmail.com	[Redacted]	1.94.2 Windows 11 25H2	Connected
izan izanro06@gmail.com	[Redacted]	1.94.2 Linux 6.17.0-19-generic	14:17 CEST
izanserver izanro06@gmail.com	[Redacted]	1.94.2 Linux 6.8.0-106-generic	Connected
redmi-note-13-5g izanro06@gmail.com	[Redacted]	1.94.2 Android 15	Mar 13



Esta herramienta también te permite gestionar el control de acceso, por usuario y dispositivo, lo que hace que sea mucho más seguro que simplemente dejándolo por defecto.

The screenshot shows the 'Access controls' section of the Novacrex dashboard. The user is logged in as 'izantro06@gmail.com' with a 'Free' account. The navigation bar includes 'Machines', 'Apps', 'Services', 'Users', 'Access controls' (active), 'Logs', 'DNS', and 'Settings'. A 'Resource hub' link is also present. The 'Access controls' page has tabs for 'Visual editor' and 'JSON editor'. Below this, a description states: 'Control who and which devices are allowed to connect in your network. If you need more advanced or customized control, or if you prefer to write in JSON directly, switch to the original JSON editor. [Learn more](#)'. A search bar is available with the placeholder 'Search by user, group, device, tag, port, IP address... etc.' and an 'Add rule' button. A table lists existing rules:

Sources	can access destinations	on port and protocol	
> All users and devices	All users and devices	All ports and protocols	ⓘ ...
> izantro06@gmail.com	All users and devices	All ports and protocols	ⓘ ...

También una herramienta interesante y muy recomendable es activar los logs, para así poder realizar auditorías.

The screenshot shows the 'Logs' section of the Novacrex dashboard. The user is logged in as 'izantro06@gmail.com' with a 'Free' account. The navigation bar includes 'Machines', 'Apps', 'Services', 'Users', 'Access controls', 'Logs' (active), 'DNS', and 'Settings'. A 'Resource hub' link is also present. The 'Logs' page has tabs for 'Configuration logs' and 'Network flow logs'. Below this, a description states: 'Inspect logs of changes made to your tailnet's configuration settings during the last 90 days. [Learn more](#)'. A 'Not streaming' status is shown with a 'Start streaming...' button. Below this, a filter section includes a 'Timeframe' dropdown set to '2026/03/29 - 2026/03/30', and 'Action', 'Actor', and 'Target' dropdowns. A table with the following headers is shown: 'TIMESTAMP (LOCAL TIME)', 'ACTION', 'ACTOR', and 'TARGET'. The table is currently empty, with a message below it stating: 'No logs found matching your filtering criteria.'



Tailscale también tiene una herramienta built-in que se llama Magic DNS con la que puedes obtener un dominio de tailscale con el que puedes buscar por nombres en vez de IPs los dispositivos o servicios vinculados a la VPN.

MagicDNS


Automatically register domain names for devices in your tailnet. This lets you to use a machine's name instead of its IP address. [Learn more](#)

Disable MagicDNS...

Existen los funnels, esta herramienta sirve para compartir algún servicio local hacia la red a nuestro gusto, usando el puerto necesario, incluso a cualquier persona de internet aunque no use tailscale, el equivalente podría ser crear una NAT con una ACL.



Pi-Hole



Introducción

Es una herramienta que permite modular tu DNS a tu gusto, su objetivo principal es implementarlo como una solución de filtrado DNS, para bloqueo de publicidad, aunque muy útil para crear nombres que sustituya la manera de buscar un servicio local de una IP a una palabra fácil de recordar. Un dato importante es que este servicio usa el puerto 53, el famoso por ser el del DNS, por lo que habría que tener cuidado al manipularlo, podríamos dejar de poder acceder a internet, se recomienda tener un segundo DNS.



Instalación y configuración

Pondremos como DNS en el netplan, dos servidores DNS distintos. Aunque en la captura de pantalla siguiente no lo refleje, se recomienda en el servidor tener una ip fija.

```
GNU nano 7.2 /etc/netplan/50-cloud-init.yaml
network:
  version: 2
  ethernets:
    eno1:
      dhcp4: true
      nameservers:
        addresses: [1.1.1.1, 8.8.8.8]
```

Aplicaremos los cambios de la red

```
izanserver@izanserver:~$ sudo netplan apply
izanserver@izanserver:~$
```

El siguiente paso es desactivar el servidor local de DNS (resolv.conf) de nuestro servidor, es algo esencial ya que Pi-hole usa el puerto

```
izanserver@izanserver:~$ sudo sed -r -i.orig 's/#?DNSStubListener=yes/DNSStubListener=no/g' /etc/systemd/resolved.conf
izanserver@izanserver:~$
```

```
izanserver@izanserver:~$ sudo ln -sf /run/systemd/resolve/resolv.conf /etc/resolv.conf
izanserver@izanserver:~$
```

Reiniciamos servicio

```
izanserver@izanserver:~$ sudo systemctl restart systemd-resolved
izanserver@izanserver:~$
```

Descargamos e instalamos automáticamente el docker de Pi-hole

```
izanserver@izanserver:~$ curl -fsSL https://get.docker.com -o get-docker.sh
izanserver@izanserver:~$
```

```
izanserver@izanserver:~$ sudo sh get-docker.sh
# Executing docker install script, commit: f381ee68b32e515bb4dc034b339266aff1fbc460
+ sh -c apt-get -qq update >/dev/null
```



Creamos un directorio exclusivo para pihole

```
izanserver@izanserver:~$ mkdir ~/pihole && cd ~/pihole
izanserver@izanserver:~/pihole$
```

Configuramos el fichero `docker-compose.yml` para PiHole. Aquí estamos definiendo los puertos necesarios, el 53 para el DNS y 80 para la interfaz web de Pihole, la zona horaria y los directorios donde actuará PiHole, IMPORTANTE: Pon tu contraseña bien.

El servicio de Pi-hole necesita usar el puerto 53 obligatoriamente, es un puerto crítico.

```
GNU nano 7.2                                docker-compose.yml *
```


```
services:
  pihole:
    container_name: pihole
    image: pihole/pihole:latest
    ports:
      - "53:53/tcp"
      - "53:53/udp"
      - "80:80/tcp"
    environment:
      TZ: 'Europe/Madrid'
      WEBPASSWORD: 'TU_CONTRASEÑA_AQUÍ'
    volumes:
      - './etc-pihole:/etc/pihole'
      - './etc-dnsmasq.d:/etc/dnsmasq.d'
    restart: unless-stopped
```

Finalmente ejecutamos el docker, lo desplegamos con el siguiente comando

```
izanserver@izanserver:~/pihole$ sudo docker compose up -d
[+] up 15/15
✓Image pihole/pihole:latest Pulled 3.4s
✓Network pihole_default Created 0.0s
✓Container pihole Started 0.5s
izanserver@izanserver:~/pihole$
```




Ahora ya podemos acceder vía Web, poniendo la IP del server y el puerto, accedemos con la contraseña (la que pusimos en el fichero de configuración)





Una vez pongamos correctamente la contraseña (la que pusimos en el fichero de configuración) estaremos dentro del Dashboard de PiHole





Galería Immich



Immich es una plataforma autohospedable de código abierto para la gestión en red de fotos videos, es la contraparte de código libre de google fotos, con estética y gestión muy similares. Se recomienda tener un disco o mejor un RAID dedicado para guardar y usar esta plataforma, para su uso se ha de abrir puertos o en mi caso usar una VPN para poder acceder al servicio ahí donde yo quiera.

La ventaja de usar esta herramienta es poder sincronizar la galería de tu móvil o otro dispositivo con el servicio Immich en tu servidor, permitiendo tener las fotos siempre disponibles desde cualquier sitio, bajar el consumo de espacio de almacenamiento en tu dispositivo, tener una mayor seguridad al tener un backup y prescindir de servicios externos de pago y caros, teniendo independencia tecnológica.

Esta herramienta está disponible como servidor en prácticamente cualquier dispositivo compatible con Docker, portainer, Unraid o TrueNAS y como cliente disponible vía Web o aplicación en Apple y Android.



En este paso se prepara el entorno de trabajo descargando los archivos de configuración necesarios (`docker-compose.yml` y un `.env` de ejemplo) directamente desde el repositorio oficial de Immich. A continuación, se inicializan todos los contenedores necesarios (servidor, base de datos Postgres, Redis y el módulo de Machine Learning) utilizando comandos de Docker Compose.

```
izanserver@izanserver:~$ mkdir ./immich-app
cd ./immich-app
izanserver@izanserver:~/immich-app$
```

```
izanserver@izanserver:~/immich-app$ wget -O docker-compose.yml https://github.com/immich-app/immich/releases/latest/download/docker-compose.yml
--2026-03-13 14:51:28-- https://github.com/immich-app/immich/releases/latest/download/docker-compose.yml
Resolving github.com (github.com)... 140.82.121.3
Connecting to github.com (github.com)|140.82.121.3|:443... connected.
HTTP request sent, awaiting response... 302 Found
Location: https://github.com/immich-app/immich/releases/download/v2.5.6/docker-compose.yml [following]
```


```
izanserver@izanserver:~/immich-app$ wget -O .env https://github.com/immich-app/immich/releases/latest/download/example.env
--2026-03-13 14:52:15-- https://github.com/immich-app/immich/releases/latest/download/example.env
Resolving github.com (github.com)... 140.82.121.3
Connecting to github.com (github.com)|140.82.121.3|:443... connected.
HTTP request sent, awaiting response... 302 Found
Location: https://github.com/immich-app/immich/releases/download/v2.5.6/example.env [following]
--2026-03-13 14:52:16-- https://github.com/immich-app/immich/releases/download/v2.5.6/example.env
Reusing existing connection to github.com:443.
HTTP request sent, awaiting response... 302 Found
```

- Rellena `UPLOAD_LOCATION` con tu ubicación preferida para almacenar los archivos de las copias de seguridad. Debería ser un directorio nuevo en el servidor con suficiente espacio libre.
- Considera cambiar `DB_PASSWORD` a un valor personalizado. Postgres no está expuesto públicamente, por lo que esta contraseña solo se usa para la autenticación local. Para evitar problemas al ser procesado por Docker, es mejor usar únicamente los caracteres A-Za-z0-9. `pwgen` es una herramienta muy práctica para esto.
- Configura tu zona horaria descomentando la línea `TZ=`.
- Rellena la información personalizada de la base de datos si fuera necesario.



```
izanserver@izanserver:~/immich-app$ sudo docker compose up -d
[sudo] password for izanserver:
[+] up 73/73
✓Image ghcr.io/immich-app/immich-server:v2          Pulled 45.1s
✓Image docker.io/valkey/valkey:9@sha256:546304417feac0874... Pulled 3.6ss
✓Image ghcr.io/immich-app/postgres:14-vectorchord0.4.3-pg... Pulled 16.4s
✓Image ghcr.io/immich-app/immich-machine-learning:v2    Pulled 28.8s
✓Network immich_default                                Created 0.0s
✓Volume immich_model-cache                             Created 0.0s
✓Container immich_machine_learning                     Started 1.1s
✓Container immich_postgres                             Started 1.1s
✓Container immich_redis                                Started 1.1s
✓Container immich_server                               Started 0.5s
izanserver@izanserver:~/immich-app$
```

Una vez que los contenedores están operativos, se realiza la primera conexión a la interfaz web de bienvenida de Immich. Este acceso se efectúa apuntando el navegador a la dirección IP del servidor y al puerto específico configurado en el despliegue.





Dado que es una instancia recién creada, el sistema requiere configurar el primer usuario, el cual obtendrá privilegios de administrador para gestionar la plataforma y la futura creación de nuevas cuentas.

Registrar administrador

i Dado que eres el primer usuario del sistema, se te designará como administrador, tendrás a tu cargo las tareas administrativas y deberás crear los demás usuarios.

Correo electrónico del administrador

izanro06@gmail.com

Contraseña del administrador

Confirmar contraseña del administrador



Nombre

Izan Rodríguez

Registrarse



Tras el registro, se accede a la vista principal del usuario, tras pulsar el botón Tema le pedirá alguna pequeña configuración básica, como el tema del fondo, si quiere usar algún otro servicio, podrá marcar o desmarcar lo que le interese. La interfaz web se presenta limpia y lista para que el administrador comience a poblar la instancia subiendo su primera fotografía.





NOVACREUX


Izan Rodríguez
Oscar Toledo

Para explotar todo el potencial de la plataforma y permitir copias de seguridad desde el teléfono, se procede a descargar e instalar la aplicación cliente oficial de Immich en el dispositivo móvil





Para enlazar la aplicación móvil con la instancia, es necesario introducir la IP y el puerto del servidor; para que esto funcione de manera remota y segura, se requiere el uso de una VPN o estar en la misma red local. Paralelamente, se comprueba a través del portal web que la primera carga de archivos se ha realizado con éxito.







NOVACREUX

Izan Rodríguez
Oscar Toledo

Como resultado final, se verifica que la plataforma funciona correctamente observando que la imagen subida ya aparece organizada en la línea de tiempo dentro de la interfaz de la aplicación cliente móvil.







NOVACREUX

Izan Rodríguez
Oscar Toledo

Al igual que la plataforma de google te permite crear álbum con el fin de poder organizar a tu gusto tu multimedia






Immich contiene una pequeña IA integrada la cual te permite realizar algunas funcionalidades, como analizar las imágenes e identificar si hay imágenes duplicadas, las cuales podrás eliminar más rápidamente, también gracias a los metadatos de las imágenes, permite identificar donde se ha realizado la imagen


Como ejemplo he subido una imagen hecha en Barcelona, la cual pulsando sobre Administrar Ubicación y seleccionando la imagen, puede determinar el lugar exacto de la imagen, ordenándola por lugar, incluso, tiene la capacidad de que el usuario marque sobre el mapa el lugar donde se ha hecho, y las coordenadas exactas.



Si en el menú de la izquierda seleccionamos carpeta protegida, podemos guardar ahí nuestras fotos que no queramos que otras personas puedan ver




Al pulsar nos permitirá protegerla con un PIN





Por supuesto, el administrador, podrá gestionar usuarios, podría crear, eliminar y modificar permisos de los usuarios



Asignando un correo, contraseña, nombre, cuota de Espacio en disco de servidor pueda usar y concederle o no privilegios de administrador

Crear nuevo usuario

Correo electrónico

Contraseña

Confirmar contraseña

Requerir que el usuario cambie la contraseña en el primer inicio de sesión ☒

Nombre

Tamaño de la cuota (GiB)


Sin límites

Usuario administrador ☐


Cancelar Crear



Nos ofrece algunas estadísticas del servidor



Como medida de seguridad extra, el propio servicio te permite generar copias de seguridad y restaurarlas cuando lamentablemente lo necesites



Es una herramienta muy bien hecha y con muchas funcionalidades aún sin explicar, para mí será mi pilar de almacenamiento en nube sin depender de ninguna empresa.



Fail2ban

Fail2ban es una herramienta de seguridad esencial en entornos Linux, actúa como sistema de prevención de intrusiones, principalmente está diseñado para prevenir intrusiones por fuerza bruta. Su funcionamiento es muy sencillo y eficaz, monitorea constantemente los archivos logs del sistema y busca patrones de comportamiento, lee posibles fallos de inicio de sesión en un corto periodo de tiempo. Además cuando detecta que una misma dirección IP intenta obtener acceso por la fuerza automáticamente levanta una regla de firewall la cual banea al atacante durante el tiempo que hayas asignado

```
izanserver@izanserver:~$ sudo apt update && sudo apt install fail2ban -y
[sudo] password for izanserver:
Obj:1 http://es.archive.ubuntu.com/ubuntu noble InRelease
Des:2 http://es.archive.ubuntu.com/ubuntu noble-updates InRelease [126 kB]
Des:3 https://download.docker.com/linux/ubuntu noble InRelease [48,5 kB]
Obj:4 http://es.archive.ubuntu.com/ubuntu noble-backports InRelease
Obj:5 http://repository.netdata.cloud/repos/edge/ubuntu noble/ InRelease
Des:6 http://es.archive.ubuntu.com/ubuntu noble-updates/universe amd64 Packages [1.689 kB]
```

```
sudo cp /etc/fail2ban/jail.conf /etc/fail2ban/jail.local
```

Se ha copiado el .conf a .local ya que fail2ban primero lee el .local ya que tiene prioridad, por lo tanto aplica las configuraciones del .local, además tener un fichero de backup de configuración

```
izanserver@izanserver:~$ sudo cp /etc/fail2ban/jail.conf /etc/fail2ban/jail.local
izanserver@izanserver:~$
```

```
sudo nano /etc/fail2ban/jail.local
```

Ahora editamos el fichero de configuración con los siguiente ficheros en el apartado de Default, bantime significa el tiempo que se baneara el usuario que intente demasiadas veces el login, findtime significa es la ventana de tiempo en el que se monitorean los intentos, es decir, desde el primer intento fallido monitorea durante el tiempo especificado los intentos, por último maxretry son la cantidad máxima de intentos que tienes en 10 minutos para que no te baneen

```
GNU nano 7.2 /etc/fail2ban/jail.local *
# The DEFAULT allows a global definition of the options. They can be overridden
# in each jail afterwards.

[DEFAULT]
bantime=10m
findtime=10m
maxretry=5
#
```




Existe un apartado especial preparado para ssh, el cual únicamente añadiremos la línea en la que activamos la opción, usando *enabled = true*

```
GNU nano 7.2 /etc/fail2ban/jail.local *
#
#
# SSH servers
#
[sshd]
enabled = true
# To use more aggressive sshd modes set filter parameter "mode" in jail.local:
# normal (default), ddos, extra or aggressive (combines all).
# See "tests/files/logs/sshd" or "filter.d/sshd.conf" for usage example and details.
#mode = normal
port = ssh
logpath = %(sshd_log)s
backend = %(sshd_backend)s
```

Por último como en todos los servicios lo reiniciamos y miramos si es correcta la configuración y si el servicio está en funcionamiento.

```
izanserver@izanserver:~$ sudo systemctl restart fail2ban
izanserver@izanserver:~$ sudo systemctl status fail2ban
● fail2ban.service - Fail2Ban Service
   Loaded: loaded (/usr/lib/systemd/system/fail2ban.service; enabled; preset: enabled)
   Active: active (running) since Mon 2026-05-11 18:46:03 UTC; 5s ago
     Docs: man:fail2ban(1)
    Main PID: 1701775 (fail2ban-server)
      Tasks: 5 (limit: 18979)
    Memory: 20.6M (peak: 20.7M)
       CPU: 165ms
    CGroup: /system.slice/fail2ban.service
            └─1701775 /usr/bin/python3 /usr/bin/fail2ban-server -xf start

may 11 18:46:03 izanserver systemd[1]: Started fail2ban.service - Fail2Ban Service.
may 11 18:46:03 izanserver fail2ban-server[1701775]: 2026-05-11 18:46:03,610 fail2ban.configr
may 11 18:46:03 izanserver fail2ban-server[1701775]: Server ready
```

Para comprobar que realmente funciona se ha instalado en un móvil una terminal e instalado ssh para poder acceder, se ha hecho así ya que bloquea IP. Hemos fallado la contraseña adrede las 5 veces y hemos comprobado que si bloquea al dispositivo durante el tiempo acordado. Fail2ban es un ejemplo de seguridad de baneo de intentos muy buena, pero a futuro se cambiará en el servidor por CrowSec, ya que esta comparte información con otros nodos independientemente donde este.

```
- $ ssh prueba@192.168.1.21
The authenticity of host '192.168.1.21 (192.168.1.21)' can't be established.
ED25519 key fingerprint is: SHA256:ks5yi+D+WJpD0fI2
P0h/OSPmfGqJPIUeMAWqrZ/8tjo
This key is not known by any other names.
Are you sure you want to continue connecting (yes/no/[fingerprint])? yes
Warning: Permanently added '192.168.1.21' (ED25519)
to the list of known hosts.
prueba@192.168.1.21's password:
Permission denied, please try again.
prueba@192.168.1.21's password:
Permission denied, please try again.
prueba@192.168.1.21's password:
prueba@192.168.1.21: Permission denied (publickey,p
assword).
- $ ssh prueba@192.168.1.21
prueba@192.168.1.21's password:
Permission denied, please try again.
prueba@192.168.1.21's password:
Permission denied, please try again.
prueba@192.168.1.21's password:
prueba@192.168.1.21: Permission denied (publickey,p
assword).
```



Uptime Kuma



Uptime Kuma es una herramienta de monitoreo de servicios autohospedados, es una herramienta de código abierto con una interfaz moderna y muy visual, su función es vigilar, se pueden configurar monitores para que revisen las aplicaciones y servicios en el servidor, además de registrar incidentes y enviar alertas, puede vigilar por puerto TCP, puede realizar pings para garantizar la red, monitorea dockers y DNS entre otras funcionalidades más.

Creemos un directorio de trabajo para que pueda usar el servicio Uptime Kuma

```
izanserver@izanserver:~$ mkdir ~/uptime-kuma && cd ~/uptime-kuma
izanserver@izanserver:~/uptime-kuma$
```

Y editamos el fichero de configuración de su docker, este servicio jugará en el puerto 3001

```
GNU nano 7.2                                docker-compose.yml *
```


```
services:
  uptime-kuma:
    image: louislam/uptime-kuma:1
    container_name: uptime-kuma
    volumes:
      - ./data:/app/data
    ports:
      - "3001:3001" # Puerto para entrar a la web
    restart: unless-stopped
```

Lanzamos y levantamos el contenedor de docker


```
izanserver@izanserver:~/uptime-kuma$ sudo docker compose up -d
[sudo] password for izanserver:
[+] up 17/17
✓Image louislam/uptime-kuma:1 Pulled 18.2s
✓Network uptime-kuma_default Created 0.8s
✓Container uptime-kuma Started 1.4s
izanserver@izanserver:~/uptime-kuma$
```



Ahora podemos acceder a su interfaz e iniciar sesión, con esto damos por instalado el servicio y operativo



Ya hemos accedido a su interfaz gráfica, donde podremos configurarla a nuestro gusto





Creamos un monitor de ejemplo, poniendo como tipo de parámetro el ping, desde la ip del servidor y que se actualizará cada 60 seg

The screenshot shows the Uptime Kuma web interface. At the top, there's a header with the Uptime Kuma logo, a 'Nueva actualización' button, a 'Páginas de estado' link, and a 'Panel' button. Below the header, there's a sidebar with a '+ Añadir nuevo monitor' button and a search bar. The main area is titled 'Editar' and contains two panels: 'General' and 'Notificaciones'. The 'General' panel has fields for 'Tipo de monitor' (set to 'Ping'), 'Nombre sencillo' (set to 'ping'), 'Nombre del host' (set to 'xxx.xxx.xxx.xxx'), 'Intervalo de latido' (set to '60'), 'Reintentos' (set to '0'), and 'Intervalo de reintento de latido' (set to '60'). The 'Notificaciones' panel has a 'Configurar notificación' button. At the bottom, there's an 'Avanzado' section with a 'Modo invertido' checkbox.

Uptime Kuma

Nueva actualización

Páginas de estado

Panel

+ Añadir nuevo monitor

Seleccionar

Buscar...

Estado

Activo

Etiquetas

100% ping

Editar

General

Tipo de monitor

Ping

Nombre sencillo

ping

Nombre del host

xxx.xxx.xxx.xxx

Intervalo de latido (Comprobar cada 60 segundos)

60

Reintentos

0

Número máximo de intentos antes de que el servicio se marque como CAÍDO y una notificación sea enviada

Intervalo de reintento de latido (Reintentar cada 60 segundos)

60

Reenviar Notificación si Caído X veces consecutivamente (Reenvío deshabilitado)

0

Notificaciones

No disponible, por favor configúralo.

Configurar notificación


Avanzado

☐ Modo invertido

Invertir el estado. Si el servicio es alcanzable, está CAÍDO



Podemos ver que si hago un ping desde el servidor al 8.8.8.8, las estadísticas comienzan a cambiar indicando que existe conexión y se está realizando un ping




Y al cabo de un rato podemos observar la siguiente estadística





Al igual que el ping, son muchos los parámetros que nos deja monitorizar, también enviar una notificación si supera un límite establezcamos.



Actualmente, la infraestructura monitoriza el estado de los servicios críticos, garantizando alta disponibilidad y una experiencia de navegación optimizada con filtrado de publicidad a nivel de red para todos los dispositivos conectados.



Netdata



Netdata es una herramienta de monitorización de la infraestructura, tiene una gran potencia y es muy fácil de escalar, implementar esta herramienta tiene como objetivo obtener una visibilidad total en tiempo real sobre el servidor, te da datos de CPU, memoria, discos, red, servicios y mucho más, con ella puedes identificar anomalías, cuellos de botella de forma muy gráfica. Netdata complementa la monitorización de Uptime Kuma con datos de rendimiento extremadamente conciso del hardware.

En esta fase se realiza la instalación rápida de Netdata utilizando un contenedor Docker. Se configuran parámetros críticos como `--pid=host` y `--network=host` para permitir que el agente tenga visibilidad directa sobre los procesos y la red del sistema operativo anfitrión. Además, se montan volúmenes en modo solo lectura (`:ro`) para que Netdata pueda leer las estadísticas del sistema (`/proc`, `/sys`) de forma segura.

```
izanserver2@izanserver2:~$ sudo apt update && sudo apt upgrade -y
Obj:1 http://archive.ubuntu.com/ubuntu noble InRelease
Obj:2 http://security.ubuntu.com/ubuntu noble-security InRelease
Obj:3 http://archive.ubuntu.com/ubuntu noble-updates InRelease
Obj:4 http://archive.ubuntu.com/ubuntu noble-backports InRelease
Leyendo lista de paquetes... Hecho
```




```
izanserver2@izanserver2:~$ docker run -d --name=netdata \  
  --pid=host \  
  --network=host \  
  -v netdataconfig:/etc/netdata \  
  -v netdatalib:/var/lib/netdata \  
  -v netdatacache:/var/cache/netdata \  
  -v /etc/passwd:/etc/passwd:ro \  
  -v /etc/group:/etc/group:ro \  
  -v /proc:/host/proc:ro \  
  -v /sys:/host/sys:ro \  
  -v /etc/os-release:/host/etc/os-release:ro \  
  -v /var/run/docker.sock:/var/run/docker.sock:ro \  
  --restart unless-stopped \  
  --cap-add SYS_PTRACE \  
  --security-opt apparmor=unconfined \  
  netdata/netdata
```

```
docker run -d --name=netdata \  
  --pid=host \  
  --network=host \  
  -v netdataconfig:/etc/netdata \  
  -v netdatalib:/var/lib/netdata \  
  -v netdatacache:/var/cache/netdata \  
  -v /etc/passwd:/etc/passwd:ro \  
  -v /etc/group:/etc/group:ro \  
  -v /proc:/host/proc:ro \  
  -v /sys:/host/sys:ro \  
  -v /etc/os-release:/host/etc/os-release:ro \  
  -v /var/run/docker.sock:/var/run/docker.sock:ro \  
  --restart unless-stopped \  
  --cap-add SYS_PTRACE \  
  --security-opt apparmor=unconfined \  
  netdata/netdata
```



Para garantizar un despliegue mantenible y escalable, se traduce la configuración anterior a un archivo `docker-compose.yml`. En este fichero se definen volúmenes persistentes (`netdataconfig`, `netdatalib`, etc.) que aseguran que las configuraciones y el historial de métricas no se pierdan tras un reinicio del contenedor. También se establece la política de reinicio `unless-stopped` para asegurar la alta disponibilidad del servicio de monitorización.

```
izanserver2@izanserver2:~$ mkdir netdata && cd netdata
izanserver2@izanserver2:~/netdata$
```

```
GNU nano 7.2                                docker-compose.yml *
```


```
version: '3'
services:
  netdata:
    image: netdata/netdata
    container_name: netdata
    pid: host
    network_mode: host
    restart: unless-stopped
    cap_add:
      - SYS_PTRACE
    security_opt:
      - apparmor:unconfined
    volumes:
      - netdataconfig:/etc/netdata
      - netdatalib:/var/lib/netdata
      - netdatacache:/var/cache/netdata
      - /etc/passwd:/etc/passwd:ro
      - /etc/group:/etc/group:ro
      - /proc:/host/proc:ro
      - /sys:/host/sys:ro
      - /etc/os-release:/host/etc/os-release:ro
      - /var/run/docker.sock:/var/run/docker.sock:ro

volumes:
  netdataconfig:
  netdatalib:
  netdatacache:
```



```
izanserver2@izanserver2:~/netdata$ docker compose up -d
```

Accedemos vía web con IP_SERVER:19999, primero hemos de registrarnos con un correo y contraseña, tras esto podremos loguearnos y como resultado nos aparecerá en la pantalla de la siguiente captura de pantalla, esta plataforma te permite monitorizar una gran cantidad de parámetros de todo el servidor, puede resultar algo abrumador de primeras, pero podemos destacar que para un usuario medio con el primer recuadro de información, la que aparece en la captura, podemos hacernos a una idea bastante detallada del estado del servidor.





n8n



N8n es una herramienta de automatización de flujos de trabajo que se basa en nodos. Una plataforma en la que puedes ver el código y autoalojarlo (fair-code), tiene una interfaz relativamente sencilla basada en nodos. Tiene contrapartes como la de Zapier, pero de pago, n8n es gratuita, mientras otras plataformas te limitan las ejecuciones, n8n solo te limita tu hardware. Tiene miles de funcionalidades, puedes gestionar los datos para big data, puedes gestionar datos de formularios, gestionar contactos con humanos, puede extraer información y transformarla con IA, es capaz de gestionar archivos, además de tener una alta integración gracias a las APIs de muchas empresas y servicios. Una de las utilidades podría ser gestionar Dockers, tanto para levantar, como para gestionar incluso para notificar mediante correo, telegram etc si alguno se cae, también para gestionar copias de seguridad o otras muchas cosas más. En resumen n8n puede ser el sistema nervioso central que es capaz de converger datos de muchas aplicaciones aisladas y usarlos y gestionarlos como a ti te convenga, una herramienta que usamos últimamente mucho.



Creamos una carpeta específica para n8n

```
izanserver@izanserver:~$ sudo mkdir -p /opt/n8n  
[sudo] password for izanserver:  
izanserver@izanserver:~$ cd /opt/n8n/  
izanserver@izanserver:/opt/n8n$
```

Creamos el docker-compose para levantar un contenedor

```
GNU nano 7.2 docker-compose.yml *  
version: "3.8"  
  
services:  
  n8n:  
    image: n8nio/n8n:latest  
    restart: always  
    ports:  
      - "5678:5678"  
    environment:  
      - TZ=Europe/Madrid  
      - GENERIC_TIMEZONE=Europe/Madrid  
      - N8N_ENFORCE_SETTINGS_FILE_PERMISSIONS=true  
      - N8N_RUNNERS_ENABLED=true  
    volumes:  
      - n8n_data:/home/node/.n8n  
  
volumes:  
  n8n_data:
```

Levantamos contenedor

```
/var/run/docker.sock  
izanserver@izanserver:/opt/n8n$ sudo docker compose up -d  
WARN[0000] /opt/n8n/docker-compose.yml: the attribute 'version' is obsolete, it will be ignored, please remove  
it to avoid potential confusion  
[+] up 16/16  
✓Image n8nio/n8n:latest Pulled 74.0s  
✓Network n8n_default Created 0.0s  
✓Volume n8n_n8n_data Created 0.0s  
✓Container n8n-n8n-1 Started 1.5s  
izanserver@izanserver:/opt/n8n$
```



Accedemos a la interfaz web vía web, con la Ip del servidor y el puerto 5678, donde iniciaremos sesión o creamos una cuenta

 **n8n**

Set up owner account

Email *

izanro06@gmail.com

First Name *

izan

Last Name *

Rodríguez Garcia


Password *

.....

8+ characters, at least 1 number and 1 capital letter

☐ I want to receive security and product updates


Next



Esto es un flujo de trabajo en N8N diseñado para ser una agente de IA personalizado con un RAG (Retrieval Augmented Generation) de documentos como base de conocimiento. N8N aquí actúa como un orquestador, es decir, un programa que gestiona los pasos que ha de seguir una IA o una cadena de programas para cumplir un objetivo final.



El flujo comienza con un webhook que va conectado a partir de un endpoint en JS en una página web, el prompt viaja en un JSON sencillo hasta el “AI Agent”, donde el agente tiene unas instrucciones de sistema personalizadas que le permiten generar respuestas basándose en los conocimientos de nuestro RAG y contestando con un estilo y formato propio. El agente utiliza Gemini Flash 3.0 como modelo principal y como backup usa un Ollama 3.2b de 8B de parámetros. La memoria y ventana de contexto de prompts está en una colección de datos en MongoDB. El encargado de almacenar y servir la base de conocimientos obtenidos por RAG es QDRANT, una base de datos vectorial open source diseñada para almacenar los índices generados por un Embedding (que para entenderlo de forma sencilla, son las herramientas encargadas de generar caracteres que identifican datos complejos para una máquina como las palabras y los indexa de forma que la IA pueda relacionar los datos a partir de coincidencias). Finalmente para terminar hacemos una normalización de datos en la salida del prompt utilizando Markdown y respondemos al webhook mandando la respuesta al endpoint del cliente y directamente a nuestro chat con la IA.



Como podemos comprobar el LLM de Gemini está conectado al agente junto con un LLM secundario en caso de fallo, el agente también tiene una Simple Memory conectada, esto permite a la IA tener una ventana de contexto configurable (en este caso está configurada para recordar todo lo que se haya hablado hace 5 prompts). También integra el nodo Qdrant en modo Retrieval, para poder recuperar los datos guardados por el sistema RAG anteriormente. También si nos fijamos hay una estructura preventiva con un IF que comprueba un parámetro de seguridad que se autogenera cada vez que se accede al sitio web.



Parameters

Settings

Execute step

Tip: Get a feel for agents with our quick [tutorial](#) or see an [example](#) of how this node works

Source for Prompt (User Message)

Define below

Prompt (User Message)

f*

{{ \$json.body.prompt }}

Require Specific Output Format

Enable Fallback Model

Connect an additional language model on the canvas to use it as a fallback if the main model fails

Options

System Message

:

Fixed

Expression

#Rol:
Actúa como el Asistente Corporativo Maestro de WeCamp, una eminencia en la gestión de campings y operaciones turísticas. Eres una inteligencia refinada, diseñada para ser el pilar de apoyo fundamental de todo el ecosistema humano de la compañía. Tu presencia es sinónimo de excelencia.

Add Option

Chat Model *

Fallback Model *

Memory



Tool



NOVACREUX

Izan Rodríguez
Oscar Toledo

La parte más importante del agente es el System Message, aquí podemos darle unas características, tareas, restricciones y condiciones personalizadas para que pueda adaptarse a nuestras necesidades.



Una vez accedemos a nuestra web podemos ver que si hablamos con nuestra IA nos responde basándose en nuestros parámetros que le hemos dado.



IA en local (PC)

Mi proyecto trata de llevar la potencia de la Inteligencia Artificial al entorno local. En lugar de mandar nuestra información a la nube, montamos el sistema en nuestros propios servidores. Así ganamos en dos cosas fundamentales: seguridad absoluta y libertad total de uso.

Se detalla el proceso de configuración de un entorno híbrido basado en Linux, utilizando contenedores Docker para la gestión de interfaces (Open WebUI), Ollama como motor de modelos de lenguaje (LLM). El objetivo principal es demostrar que, con hardware de consumo (RTX 4060 Ti 16GB), es posible alcanzar flujos de trabajo profesionales en IA con latencia mínima y control total sobre los modelos, en el proyecto el único elemento limitante es nuestro hardware, para potenciar aún más la IA que usemos, se ha de tener de principalmente una grafica de mas potencia y sobretodo más memoria integrada.



Hardware usado:

	PC Personal de Izan
CPU:	Intel i5-13600KF
RAM:	2 x 8GB Kingston Fury 3200Mhz
GPU:	Zotac Nvidia 4060TI 16gb VRAM
Disco duro:	1TB NVME M.2 Kingston



Antes de empezar

Antes de empezar: Consideraciones y Requisitos

Antes de proceder con la instalación, es fundamental asegurarse de que el entorno cumple con los requisitos técnicos y de configuración para garantizar un rendimiento óptimo de la IA en local.

1. Requisitos de Hardware (Especificaciones del Proyecto)

Este despliegue ha sido testado y optimizado para la siguiente configuración:

- **GPU:** NVIDIA GeForce RTX 4060 Ti (16GB VRAM). *La memoria de vídeo es el factor crítico para cargar modelos como Mistral 24B sin recurrir a la memoria RAM del sistema, lo que ralentizaría el proceso.*
- **SO:** Linux (Ubuntu/Debian recomendado) con drivers de NVIDIA actualizados y soporte para CUDA.
- **Almacenamiento:** Se recomienda un SSD con al menos 40GB de espacio libre para el almacenamiento de pesos de modelos y contenedores.

2. Dependencias de Software

Es necesario contar con las siguientes herramientas instaladas o permisos para instalarlas:

- **Docker:** Para el aislamiento de la interfaz de usuario.
- **Python 3.10+:** Necesario para los entornos virtuales de ComfyUI.
- **Privilegios Sudo:** Para la gestión de servicios del sistema (Systemd) y permisos de Docker.



Instalación de Ollama, verificación del servicio, Descarga del modelo.

Para comenzar, instalamos **Ollama**, que actuará como el backend o "cerebro" encargado de ejecutar los modelos de Inteligencia Artificial en local.

Comando usado: `curl -fsSL https://ollama.com/install.sh | sh`


```
izan@izan:~$ curl -fsSL https://ollama.com/install.sh | sh
>>> Installing ollama to /usr/local
[sudo] contraseña para izan:
>>> Downloading ollama-linux-amd64.tar.zst
##### 100.0%
>>> Creating ollama user...
>>> Adding ollama user to render group...
>>> Adding ollama user to video group...
>>> Adding current user to ollama group...
>>> Creating ollama systemd service...
>>> Enabling and starting ollama service...
Created symlink /etc/systemd/system/default.target.wants/ollama.service → /etc/systemd/system/ollama.service.
>>> NVIDIA GPU installed.
izan@izan:~$
```

Ejecutamos el script de instalación automática oficial. Este comando descarga los binarios necesarios, crea el usuario de sistema **ollama** y configura los servicios para que se inicien automáticamente con el sistema. Como se observa en el log, el instalador detecta correctamente el hardware gráfico (**NVIDIA GPU installed**), lo cual es crucial para la aceleración por hardware.

Una vez finalizada la instalación, verificamos que el servicio está activo y escuchando peticiones. Para ello, accedemos desde el navegador a la dirección local del puerto por defecto de la API de Ollama.

<http://localhost:11434> o <http://127.0.0.1:11434>

si aparece el siguiente mensaje la instalación se ha hecho correctamente





Descarga de modelos (LLM)

Con el servicio activo, procedemos a descargar nuestro primer modelo de lenguaje. Utilizamos el comando `ollama pull [nombre_modelo]` (Se recomienda hacer primero una búsqueda de qué modelo queremos o que podemos ejecutar, cada uno tiene sus características)

En la primera captura se observa un error al intentar descargar una versión inexistente o mal escrita (`dolphin-mistral-nemo`), por lo que el sistema devuelve "manifest file does not exist".

```
izan@izan:~$ ollama pull dolphin-mistral-nemo
pulling manifest
Error: pull model manifest: file does not exist
izan@izan:~$
```

Posteriormente, se ejecuta la descarga correcta del modelo **Mistral Nemo** (un modelo eficiente de 12B parámetros). El sistema descarga las diferentes capas (sha256 digest) y verifica la integridad del archivo manifiesto para finalizar la instalación en la librería local.

```
izan@izan:~$ ollama pull mistral-nemo
pulling manifest
pulling b559938ab7a0: 100% 7.1 GB
pulling 438402ddac75: 100% 683 B
pulling 43070e2d4e53: 100% 11 KB
pulling ed11eda7790d: 100% 30 B
pulling 65d37de20e59: 100% 486 B
verifying sha256 digest
writing manifest
success
izan@izan:~$
```




Instalación de docker, Despliegue de Open WebUI, Configuración inicial

Instalación del Entorno de contenedores

Para ejecutar la interfaz gráfica de forma aislada y segura, utilizamos **Docker**. Procedemos a actualizar los repositorios e instalar el paquete [docker.io](https://docs.docker.com/engine/install/ubuntu/).

Actualizamos la lista de paquetes del sistema y procedemos a la instalación del motor de contenedores Docker desde los repositorios oficiales de Ubuntu.

Comando usado: `sudo apt update && sudo apt install docker.io -y`

```
izan@izan:~$ sudo apt update
sudo apt install docker.io -y
[sudo] contraseña para izan:
Obj:1 http://security.ubuntu.com/ubuntu noble-security InRelease
Obj:2 https://ppa.launchpadcontent.net/danielrichter2007/grub-customizer/ubuntu noble InRelease
Obj:3 http://archive.ubuntu.com/ubuntu noble InRelease
Obj:4 http://archive.ubuntu.com/ubuntu noble-updates InRelease
Obj:5 http://archive.ubuntu.com/ubuntu noble-backports InRelease
Leyendo lista de paquetes... Hecho
Creando árbol de dependencias... Hecho
```

Una vez instalado, es necesario añadir nuestro usuario actual al grupo de seguridad **docker**. Esto permite ejecutar contenedores sin necesidad de utilizar **sudo** constantemente, mejorando la seguridad y la comodidad del flujo de trabajo. Aplicamos los cambios de grupo inmediatamente con el comando **newgrp**.

Comando usado: `sudo usermod -aG docker $USER` y `newgrp docker`

```
izan@izan:~$ sudo usermod -aG docker $USER
izan@izan:~$
```

```
izan@izan:~$ newgrp docker
izan@izan:~$
```



Despliegue de Open WebUi

Desplegamos la interfaz **Open WebUI** utilizando un contenedor Docker. Esta interfaz se conectará automáticamente a nuestro servicio local de Ollama.

Ejecutamos el contenedor con la configuración de red en modo **host** (para que pueda ver a Ollama en el puerto 11434 local) y configuramos un volumen persistente para que nuestros chats y configuraciones no se borren al reiniciar.

comando usado: `docker run -d --network host -v open-webui:/app/backend/data --name open-webui --restart always ghcr.io/open-webui/open-webui:main`

Explicación de flags:

- `--network host`: Comparte la red con el PC (vital para conectar con Ollama).
- `--restart always`: Si el PC se reinicia, el chat arranca solo.
- `-v open-webui:....`: Guarda tus datos en un disco virtual seguro.

```
open-webui
izan@izan:~$ docker run -d --network host -v open-webui:/app/backend/data --name open-webui --restart always ghcr.io/open-webui/open-webui:
main
4ad617fd8b515b21dc0f7e62585544a622dc062ca3a286bfdad7a80d365db388
izan@izan:~$
```



NOVACREUX

Izan Rodríguez
Oscar Toledo

Configuración Inicial y primer chat

<http://localhost:8080>





Accedemos a la interfaz web a través del navegador en <http://localhost:8080>. Al ser la primera vez, el sistema solicita crear una cuenta de administrador. *Nota: Estos datos son totalmente locales; no se envían a ningún servidor externo.*

Open WebUI

http://localhost:3000/auth?redirect=%2F

OI

Empezar con Open WebUI

Open WebUI no se realiza ninguna conexión externa y tus datos permanecen seguros alojados localmente en tu servidor.

Nombre
Ingresa su nombre completo


Email
Ingresa tu correo electrónico

Contraseña
Ingresa tu contraseña

Crear Cuenta Administrativa



Una vez dentro, la interfaz detecta automáticamente los modelos descargados en Ollama (como Mistral). Seleccionamos el modelo en el menú superior y realizamos una prueba de generación de texto. El sistema responde correctamente, confirmando la integración exitosa entre Docker (Frontend) y Ollama (Backend).





Exposición de Ollama a la Red

Por defecto, Ollama solo escucha peticiones locales (127.0.0.1). Para que el contenedor Docker de Open WebUI pueda comunicarse con él, debemos permitir conexiones externas.

Editamos la configuración del servicio de sistema de Ollama para cambiar su dirección de escucha (Bind Address).

comandos usados: `sudo systemctl edit ollama.service`

```
izan@izan:~$ sudo systemctl edit ollama.service
[sudo] contraseña para izan:
izan@izan:~$
```

```
[Service]
# ExecStart=/usr/local/bin/ollama serve
# User=ollama
# Group=ollama
# Restart=always
# RestartSec=3
# Environment="PATH=/usr/local/sbin:/usr/local/bin:/usr/sbin:/usr/bin:/sbin:/bin:/usr/games:/usr/local/games:/usr/local/sbin"
# Environment="OLLAMA_HOST=0.0.0.0"
# [Install]
# WantedBy=default.target
```

Esto indica a Ollama que acepte conexiones desde cualquier interfaz de red, incluyendo la interfaz virtual de Docker.

comandos usados:

`sudo systemctl daemon-reload`

`sudo systemctl restart ollama`

```
izan@izan:~$ sudo systemctl daemon-reload
izan@izan:~$ sudo systemctl restart ollama
izan@izan:~$
```



Integración Final en OpenWebUI



Finalmente, conectamos la interfaz de chat con el cerebro de IA.

Esto es necesario si queremos acceder a usar nuestra IA personal desde otro dispositivo (Incluso móvil) en nuestra misma red.

Accedemos a **Open WebUI** → **Panel de Administración** → **Ajustes** → **Conexiones**. En el campo "Ollama Base URL", establecemos la dirección que apunta a nuestro host local.

URL de conexión: <http://host.docker.internal:11434> (Alternativamente, si usamos red host: <http://127.0.0.1:11434>)


Al guardar, verificamos la conexión. Ahora, desde el chat principal, podemos desplegar la lista de modelos y seleccionar **Mistral** o **Llama** para interactuar. El sistema está 100% operativo en local.






Funcionalidades

En la parte superior izquierda de la ventana observamos el modelo de IA que estamos usando, según los que tengamos instalados podemos usarlos. Aunque el máximo de la tarjeta sea de 24B de parámetros, hay instalado uno de 32B, ¿cómo es posible, si el límite es 24B? Aunque digamos que el límite es 24B ese es límite que la tarjeta puede almacenar enteramente en su VRAM, en este caso tendremos 24B metidos en la memoria de la gráfica y 8B en la RAM del ordenador, no se recomienda superar el límite de tu tarjeta ya que ira extremadamente lenta cada respuesta.





En la parte inferior, puedes darle permiso para que para tu respuesta pueda consultar en internet, si es que de base no puede obtener información suficiente para contestar de una manera decente, también tiene un modo especial para leer, escribir y que el usuario edite código que la IA pueda interpretar






Si pulsamos en + podemos ver lo siguiente:


- subir archivo: puedes subir varios tipos de archivo para que lo use como medio de conocimiento
- Captura: Realizará una captura de pantalla que se adjunta al chat
- Adjuntar página Web: Adjuntaras la URL de la página web a la que quieras referenciar
- Adjuntar Notas: Podrás crear instrucciones como notas para que lo tenga en cuenta
- Adjuntar conocimiento: Anteriormente a usarlo podrás crear conocimiento, esto es un paquete de archivos, textos o medios para que coja como fuente fiable. Muy útil si tienes ya material diverso preparado y clasificado.
- Referenciar chats: Podrás seleccionar un chat que hayas hecho antes para que extraiga el contexto.



Adjuntar notas




Referenciar chats




Adjuntar conocimiento




si pulsamos en nuestro perfil, si tenemos permisos podremos acceder a zona de pruebas



Aquí podremos ingresar algunas instrucciones básicas para que a la hora de contestar siempre tenga en cuenta, sea el prompt que sea que le pases.



Desde ajustes podremos crear usuarios nuevos, con su email propio, contraseña y su rol, si se ha de importar varios se puede mediante CSV.





Al igual que las IAs comerciales puede leer algunos archivos, entre ellos los pdfs, en la siguiente captura demuestro como pasandole un manual de productos de LG, es capaz de hacerme un resumen

http://localhost:3000/c/5d718b5e-be6d-4274-85a8-0403427721b0

huihui_ai/mistral-small-abliterated:24b

LG_Manual.pdf 8.3 MB

Lee el pdf que te paso y hazme un resumen de que trata y unos pocos puntos a destacar

huihui_ai/mistral-small-abliterated:24b
Recuperada una fuente

El PDF que has proporcionado parece ser un manual de usuario para un dispositivo LG. A continuación, te presento un resumen del contenido y algunos puntos destacados:

Resumen:

El manual proporciona instrucciones detalladas sobre cómo utilizar diversas funciones del dispositivo LG, incluyendo la reproducción de música, la gestión de fotos y la instalación del televisor.

Puntos Destacados:

- Reproducción de Música:**
 - La música en una carpeta se reproduce en secuencia.
 - Es posible marcar archivos de música para reproducirlos en un orden específico o repetidamente [LG_Manual.pdf](#).
 - El cuadro de información de reproducción se mueve automáticamente por la pantalla si no hay acción del usuario.
- Gestión de Fotos:**
 - Las fotos pueden ser marcadas y desmarcadas utilizando el botón MARK.
 - Es posible ver las fotos marcadas individualmente o en una presentación [LG_Manual.pdf](#).
 - Las opciones incluyen cancelar la selección, borrar fotos seleccionadas y cerrar menús emergentes.
- Instalación del Televisor:**
 - Se recomienda colocar la pantalla de la TV sobre una superficie acolchada para protegerla.
 - La instalación incluye ajustes de pernos y separación del soporte [LG_Manual.pdf](#).

Si necesitas más detalles específicos o tienes alguna otra pregunta, por favor házmelo saber.

1 Fuente

✎ 📄 🔊 ⌂ 👍 🗨️ 🔄



Monitorización en IA


Como método de monitorización en directo usaremos Glances, es un contenedor docker que no es muy habitual, pero podemos ver de manera muy cómoda muchos datos muy útiles que nos permite ver la utilización del hardware mientras ejecutamos modelos de IA

```
docker run -d \
  --name glances \
  --restart always \
  --network host \
  --pid host \
  --privileged \
  -v /var/run/docker.sock:/var/run/docker.sock:ro \
  -e GLANCES_OPT="-w" \
  nicolargo/glances
```

La instalación es muy sencilla ya que es un docker, seguimos el siguiente comando


```
izan@izan:~$ docker run -d --name glances -p 61208:61208 -v /var/run/docker.sock:/var/run/docker.sock:ro nicolargo/glances
Unable to find image 'nicolargo/glances:latest' locally
latest: Pulling from nicolargo/glances
6a0ac1617861: Pull complete
e888e961bdc6: Pull complete
06606c46da23: Pull complete
d4b3b86ef18d: Pull complete
192c9a59a80c: Pull complete
4ff71ce6d66b: Pull complete
4f4fb70ef54: Pull complete
46f1535c115b: Pull complete
Digest: sha256:8e138cbfa3cf1eea59633e3a173c38b0c98267db9d506bf47c2a20678c9e9f37
Status: Downloaded newer image for nicolargo/glances:latest
83fda3164a677237f4abb6498ef24a86d9d79eee233f7ecc2dfecce09aca7eab
izan@izan:~$
```

Para acceder a esta herramienta de monitorización simplemente añadiremos en nuestro navegador la IP del PC del que hemos ejecutado el docker junto al puerto :61208






Usando otra IA comercial hemos solicitado que nos prepare un prompt algo exigente, el cual colocaremos en OpenWebUI.



Durante la ejecución del prompt entramos en la herramienta de monitorización y podemos observar que las estadísticas cambian. [Monitorización Glandes](#)






Raspberry Pi + HAT AI

Una alternativa muy usada en muchos ámbitos de la informática es usar la plataforma raspberry, ya que cuenta con puntos a favor que poco hardware puede ofrecer por su precio, este tipo de hardware es muy común entre aficionados a la informática y tiene un uso muy extendido.

Nos concede una potencia considerable a un precio relativamente bajo, con un consumo ridículo, además de tener una modularidad grande.

Nosotros contamos con una Raspberry Pi 5 de 8GB de RAM, con un módulo extra llamado AI HAT+ 2 lo que hace que sea superior en calculos rapidos, los que necesita la IA para funcionar mejor, en nuestro proyecto estamos probando varias plataformas donde ejecutar distintos tipos de IA, en este dispositivo haremos funcionar una IA capaz de describir las imágenes que obtiene, lo que en el sector empresario significa poder detectar riesgos laborales, humo o cualquier tipo de objeto sin necesidad de intervención humana.

Donde a raíz de estas descripciones puede activar protocolos, notificar sobre cualquier cosa o realizar algunas acciones.






Instalación de Sistema Operativo

Para poder instalar el sistema operativo de la raspberry pi utilizaremos el software “Raspberry Pi Imager”. Es un software que ejecutamos desde un PC, conectamos al PC la tarjeta SD y realizamos los siguientes pasos.





Escogeremos el sistema operativo completo con entorno gráfico ya que para ciertas pruebas físicas necesitaremos un output visual.



Raspberry Pi Imager v2.0.6

Pasos de configuración

Dispositivo

SO

Almacenamiento

Personalización

Nombre del equipo

Localización

Usuario

Wi-Fi

Acceso remoto

Seleccione su dispositivo de almacen...



Kingston DataTraveler 3.0 USB Device

115.5 GB

Montado como D:\

☒ Excluir unidades del sistema

OPCIONES DE LA APL...

VOLVER

SIGUIENTE

Montamos el sistema operativo sobre un Pendrive para instalarlo posteriormente sobre la propia raspberry.

66/121



Raspberry Pi Imager v2.0.6

Dispositivo

SO

Almacenamiento

Personalización

Nombre del equipo

Localización

Usuario

Wi-Fi

Acceso remoto

Raspberry Pi Connect

Personalización: Elija el nombre de equipo

Introduzca su nombre de equipo

izan-oscar-proyectoasix

Un nombre de equipo es un nombre único que identifica su Raspberry Pi en la red. Solo debe contener letras, números y guiones.

OPCIONES DE LA APL...

OMITIR PERSONALIZACIÓN

VOLVER

SIGUIENTE

Nuestro nombre de host será: izan-oscar-proyectoasix. Este es el nombre de la máquina Raspberry.



Ponemos el huso horario de Madrid

Raspberry Pi Imager v2.0.6

SO

Almacenamiento

Personalización

Nombre del equipo

Localización

Usuario

Wi-Fi

Acceso remoto

Raspberry Pi Connect

Escritura

Personalización: Localización

Seleccione su ubicación para obtener sugerencias sobre la zona horaria y

Capital:

Madrid (Spain)

Zona horaria:

Europe/Madrid

Distribución del teclado:

es

OPCIONES DE LA APL...

OMITIR PERSONALIZACIÓN

VOLVER

SIGUIENTE



Configuramos el usuario, pondremos iokip y contraseña usaremos P@ssw0rd, (Si no fuera un proyecto en un ámbito cerrado y esto fuera una implementación en un entorno real y en producción no usaremos una contraseña insegura, ni la revelaremos).

Raspberry Pi Imager v2.0.6

Almacenamiento

Personalización

Nombre del equipo

Localización

Usuario

Wi-Fi

Acceso remoto

Raspberry Pi Connect

Escritura

Hecho

Personalización: Elegir nombre de usuario

Crea una cuenta de usuario para su Raspberry Pi

Nombre de usuario:

Introduzca su nombre de usuario

iokip

Contraseña:

Introduzca la contraseña

••••••••

👁

Confirmar contraseña:

Vuelva a introducir la contraseña

••••••••

👁

El nombre de usuario debe estar en minúsculas y contener solo letras, números, guiones bajos y guiones.

OPCIONES DE LA APL...

OMITIR PERSONALIZACIÓN

VOLVER

SIGUIENTE



Configuramos el Wifi, aunque como siempre es recomendable ir por cable, nosotros usaremos el Wifi para poder trabajar mejor desde distintos puntos de la clase.

Raspberry Pi Imager v2.0.6

Almacenamiento

Personalización

Nombre del equipo

Localización

Usuario

Wi-Fi

Acceso remoto

Raspberry Pi Connect

Escritura

Hecho

OPCIONES DE LA APL...

OMITIR PERSONALIZACIÓN

VOLVER

SIGUIENTE

Personalización: Elegir Wi-Fi

RED SEGURA

RED ABIERTA

SSID:

Nombre de la red

Livebox6-00F7

Contraseña:

Contraseña de la red

.....

👁

Confirmar contraseña:

Vuelva a introducir la contraseña

.....

👁

☐ SSID oculta



Activaremos el SSH, esta herramienta nos permitirá administrar la Raspberry desde otro dispositivo de manera más sencilla y cómoda, incluso sin estar cerca del hardware.

Raspberry Pi Imager v2.0.6

Personalización: Autenticación SSH

Configure SSH access

Activar SSH More information about SSH

Mecanismo de autenticación:

- ☒ Usar autenticación por contraseña
- ☐ Usar autenticación con clave pública

OPCIONES DE LA APL... OMITIR PERSONALIZACIÓN VOLVER SIGUIENTE

Tras toda la configuración ya pasaremos a escribir sobre la tarjeta SD.

Raspberry Pi Imager v2.0.6

Escribir imagen

Escritura en curso, no desconecte el dispositivo de almacenamiento

Escribiendo... 29%

Limited by storage device speed (14 MB/s)

OPCIONES DE LA APL... VOLVER CANCELAR ESCRITURA



Desde el portátil ejecutamos Fing, este programa sirve para escanear tu red wifi y así hallar entre varios dispositivos cuál es el que nos interesa y alguna información como el nombre del equipo, su IP, dirección MAC y otra información.

The screenshot shows the Fing application interface. On the left is a blue sidebar with navigation options: Panorama, Dispositivos (selected), Red, Seguridad, Internet, Gente, Herramientas, and Notificaciones. At the bottom of the sidebar, it says 'Fing 3.10.1' and 'Izan Rodríguez'. The main area is titled 'Dispositivos • Livebox6-00F7' and includes a 'Sin monitoreo' status and a 'Última actualización ahora' timestamp. A yellow warning banner states: 'Aún no se ha asignado un contexto para Livebox6-00F7. Algunas funciones pueden estar deshabilitadas. [Asignar un contexto](#)'. Below this is a search bar and filters for 'Todo' and 'Estado'. A table lists the detected devices:

TIPO	NOMBRE	DETALLES	CAMBIADO	STATUS
	izan-oscar-proyectoasix	Raspberry Pi	16:08	
	LIVEBOX	Arcadyan • PRV33AX349B-B	Router	
	F2WORK	Lenovo • ThinkPad P16s Gen 2	Laptop Windows	
	DESKTOP-30K5TS6	Asus • VivoBook K3605ZF	Laptop Windows 11 Pro	
	Computer	HPE	Computer Windows	
	Computer	HPE	Computer Windows	
	Computer	HPE	Computer Windows	



Tras el escaneo ya hemos encontrado la Raspberry, podemos reconocerla por el nombre de máquina que tiene, podemos ver que nos dice lo siguiente:

- Nombre de máquina
- Tipo de equipo, que es una Raspberry Pi
- IP
- Dirección MAC
- Si esta en línea o lo ha estado hace poco

The screenshot shows the Fing application interface. On the left is a blue sidebar with navigation options: Panorama, Dispositivos, Red, Seguridad, Internet, Gente, Herramientas, and Notificaciones. The main area is titled 'Detalles del dispositivo' and shows details for a device named 'izan-oscar-proyectoasix' (Raspberry Pi). The status is 'En línea' (Online) with a green dot and 'hace 7 minutos' (7 minutes ago). Below this is a table for 'Configuración de la red' (Network Configuration) and a section for 'Dispositivo' (Device) showing the brand and model.

Configuración de la red	
Dirección IP:	192.168.1.62
Dirección MAC	88:A2:9E:C8:80:65
Número de serie	N/A
Visto por primera vez	16:08
Última modificación	16:08

Dispositivo	
Marca e Modelo	
Marca	Raspberry Pi



Nos conectamos por SSH y comprobar que funciona

```
C:\Users\Izan>ssh iokip@192.168.1.62
iokip@192.168.1.62's password:
Linux izan-oscar-proyectoasix 6.12.47+rpt-rpi-2712 #1 SMP PREEMPT Debian 1:6.12.47-1+rpt1 (2025-09-16) aarch64


The programs included with the Debian GNU/Linux system are free software;
the exact distribution terms for each program are described in the
individual files in /usr/share/doc/*/copyright.

Debian GNU/Linux comes with ABSOLUTELY NO WARRANTY, to the extent
permitted by applicable law.
Last login: Wed Mar 25 16:09:31 2026 from 192.168.1.48
iokip@izan-oscar-proyectoasix:~ $ pwd
/home/iokip
iokip@izan-oscar-proyectoasix:~ $ whoami
iokip
```

Acceder al entorno GUI sin cables, nuestra segunda manera de administrar la raspberry fuera de los comandos, hemos de activar el VNC, para ello accedemos al siguiente menú de configuración


```
iokip@izan-oscar-proyectoasix:~ $ sudo raspi-config
iokip@izan-oscar-proyectoasix:~ $
```

Accedemos a interface Options






Accedemos a VNC y lo permitiremos




Una vez instalado desde nuestro PC buscaremos una aplicación para usar VNC, en mi caso usaré RealVNC, con esta nos bastará. Ponemos la IP de la raspberry y el usuario y contraseña





Con esto ya hemos podido acceder sin cables a la GUI de la raspberry





Instalación de dependencias y ollama

```
iokip@izan-oscar-proyectoasix:~$ sudo apt update && sudo apt full-upgrade -y
Hit:1 http://deb.debian.org/debian trixie InRelease
Hit:2 http://deb.debian.org/debian trixie-updates InRelease
Hit:3 http://deb.debian.org/debian-security trixie-security InRelease
Hit:4 http://archive.raspberrypi.com/debian trixie InRelease
23 packages can be upgraded. Run 'apt list --upgradable' to see them.
Calculating upgrade... 10%
```

Actualizamos todos los paquetes de la raspberry

```
iokip@izan-oscar-pr...$ sudo apt install dkms hailo-h10-all -y
The following packages were automatically installed and are no longer required:
  alacarte          gnome-menus  libgnome-menu-3-0  retry
  gir1.2-gmenu-3.0  gtk-nop     python3-gi-cairo
Use 'sudo apt autoremove' to remove them.

Installing:
  dkms  hailo-h10-all

Installing dependencies:
  bzip2-doc          libodbc2
  cmake              libodbcrc2
  cmake-data         libodbcinst2
  comerr-dev         libogdi4.1
  cppzmq-dev         libopencv-calib3d-dev
  gdal-data          libopencv-contrib-dev
  gdal-plugins       libopencv-contrib410
  gir1.2-freedesktop-dev  libopencv-core-dev
  gir1.2-girepository-2.0-dev  libopencv-dev
  gir1.2-glib-2.0-dev    libopencv-dnn-dev
  gir1.2-gst-plugins-bad-1.0  libopencv-features2d-dev
  gir1.2-gst-plugins-base-1.0  libopencv-flann-dev
  gir1.2-gstreamer-1.0    libopencv-highgui-dev
  gir1.2-gudev-1.0       libopencv-highgui410
  girepository-tools    libopencv-imgcodecs-dev
  gobject-introspection  libopencv-imgcodecs410
  gobject-introspection-bin  libopencv-imgproc-dev
  gstreamer1.0-tools    libopencv-java
  h10-hailort           libopencv-ml-dev
  h10-hailort-pcie-driver  libopencv-ml410
  hailo-models          libopencv-objdetect-dev
  hailo-tappas-core     libopencv-photo-dev
  krb5-multidev         libopencv-photo410
  libaec0               libopencv-shape-dev
  libamd-comgr2         libopencv-shape410
  libamdhip64-5         libopencv-stitching-dev
  libarmadillo14        libopencv-stitching410
  libarpack2t64         libopencv-superres-dev
  libavcodec-dev        libopencv-superres410
  libavformat-dev       libopencv-video-dev
  libavutil-dev         libopencv-video410
```




Instalamos todas las dependencias del módulo AI HAT 2

```
iokip@izan-oscar-proyectoasix:~ $ hailortcl1 fw-control identify
Executing on device: 0001:01:00.0
Identifying board
Control Protocol Version: 2
Firmware Version: 5.1.1 (release,app)
Logger Version: 0
Device Architecture: HAILO10H

iokip@izan-oscar-proyectoasix:~ $
```

```
iokip@izan-oscar-proyectoasix:~
File Edit Tabs Help

iokip@izan-oscar-proyectoasix:~ $ sudo apt install uidmap dbus-user-session -y
dbus-user-session is already the newest version (1.16.2-2).
dbus-user-session set to manually installed.
The following packages were automatically installed and are no longer required:
  alacarte          gnome-menus libgnome-menu-3-0 retry
  gir1.2-gmenu-3.0 gtk-nop      python3-gi-cairo
Use 'sudo apt autoremove' to remove them.

Installing:
  uidmap

Installing dependencies:
  libsubid5

Summary:
  Upgrading: 0, Installing: 2, Removing: 0, Not Upgrading: 0
  Download size: 411 kB
  Space needed: 783 kB / 107 GB available

Get:1 http://deb.debian.org/debian trixie/main arm64 libsubid5 arm64 1:4.17.4-2
[219 kB]
Get:2 http://deb.debian.org/debian trixie/main arm64 uidmap arm64 1:4.17.4-2 [19
3 kB]
Fetched 411 kB in 0s (2,551 kB/s)
```

Instalamos las dependencias de docker y después descargamos el script de descarga de docker rootless (Esto evita que un contenedor comprometido escale privilegios a nivel de kernel de la Pi).

```
iokip@izan-oscar-proyectoasix:~ $ sudo usermod -aG docker $USER
iokip@izan-oscar-proyectoasix:~ $ newgrp docker
iokip@izan-oscar-proyectoasix:~ $
```



```
iokip@izan-oscar-proyectoasix: ~  
File Edit Tabs Help  
iokip@izan-oscar-proyectoasix:~ $ sudo systemctl status docker.service  
● docker.service - Docker Application Container Engine  
   Loaded: loaded (/usr/lib/systemd/system/docker.service; enabled; preset: enabled)  
   Active: active (running) since Mon 2026-03-30 22:07:03 CEST; 1min 40s ago  
 Invocation: 6a2032aae3214055a7b9829d0485cae8  
 TriggeredBy: ● docker.socket  
    Docs: https://docs.docker.com  
   Main PID: 3020 (dockerd)  
     Tasks: 11  
      CPU: 209ms  
   CGroup: /system.slice/docker.service  
           └─3020 /usr/bin/dockerd -H fd:// --containerd=/run/containerd/containerd.sock  
  
Mar 30 22:07:01 izan-oscar-proyectoasix dockerd[3020]: time="2026-03-30T22:07:01.367298345+02:00" lev>  
Mar 30 22:07:02 izan-oscar-proyectoasix dockerd[3020]: time="2026-03-30T22:07:02.345558585+02:00" lev>  
Mar 30 22:07:02 izan-oscar-proyectoasix dockerd[3020]: time="2026-03-30T22:07:02.352109663+02:00" lev>  
Mar 30 22:07:02 izan-oscar-proyectoasix dockerd[3020]: time="2026-03-30T22:07:02.352131144+02:00" lev>  
Mar 30 22:07:02 izan-oscar-proyectoasix dockerd[3020]: time="2026-03-30T22:07:02.352152866+02:00" lev>  
Mar 30 22:07:02 izan-oscar-proyectoasix dockerd[3020]: time="2026-03-30T22:07:02.352264514+02:00" lev>  
Mar 30 22:07:03 izan-oscar-proyectoasix dockerd[3020]: time="2026-03-30T22:07:03.175893680+02:00" lev>  
Mar 30 22:07:03 izan-oscar-proyectoasix dockerd[3020]: time="2026-03-30T22:07:03.181130746+02:00" lev>  
Mar 30 22:07:03 izan-oscar-proyectoasix dockerd[3020]: time="2026-03-30T22:07:03.181198245+02:00" lev>  
Mar 30 22:07:03 izan-oscar-proyectoasix systemd[1]: Started docker.service - Docker Application Conta  
lines 1-22/22 (END)
```

Instalamos el ollama, pero al no tener una gráfica normal como una NVIDIA o AMD, se necesita instalar por otro lado

```
iokip@izan-oscar-proyectoasix:~ $ curl -fsSL https://ollama.com/install.sh | sh  
>>> Installing ollama to /usr/local  
>>> Downloading ollama-linux-arm64.tar.zst  
##### 100.0%  
>>> Creating ollama user...  
>>> Adding ollama user to render group...  
>>> Adding ollama user to video group...  
>>> Adding current user to ollama group...  
>>> Creating ollama systemd service...  
>>> Enabling and starting ollama service...  
Created symlink '/etc/systemd/system/default.target.wants/ollama.service' → '/etc/systemd/system/ollama.service'.  
>>> The Ollama API is now available at 127.0.0.1:11434.  
>>> Install complete. Run "ollama" from the command line.  
WARNING: No NVIDIA/AMD GPU detected. Ollama will run in CPU-only mode.  
iokip@izan-oscar-proyectoasix:~ $ curl
```



Instalación de openclaw

```
iokip@izan-oscar-proyectoasix:~$ curl -fsSL https://openclaw.ai/install.sh | bash

███ OpenClaw Installer
Think different. Actually think.

✓ Detected: linux

Install plan
OS: linux
Install method: npm
Requested version: latest
```

Descargamos openclaw, que es un agente de IA autónomo open source, diseñado para ser self-hosted. Openclaw es capaz de ejecutar acciones reales en nuestro ordenador o servidor. Ejecutando el script de instalación en bash utilizando el comando que vemos en la imagen superior.

```
[1/3] Preparing environment
- Node.js not found, installing it now
- Installing Node.js via NodeSource
- Installing Linux build tools (make/g++/cmake/python3)
✓ Build tools installed
✓ Node.js v22 installed
- Active Node.js: v22.22.2 (/usr/bin/node)
- Active npm: 10.9.7 (/usr/bin/npm)
```

Una vez comience la descarga, en caso de no encontrar [Node.js](https://nodejs.org/) lo instalará automáticamente junto con NPM.

```
[2/3] Installing OpenClaw
✓ Git already installed
- Configuring npm for user-local installs
✓ npm configured for user installs
- Installing OpenClaw v2026.4.14
```



También descargará Git en caso de no estar instalado.

```
[[[OpenClaw 2026.4.14 (323493f)
Running on your hardware, reading your logs, judging nothing (mostly).

OPENCLAW

[[[OPENCLAW [[[

OpenClaw setup
• Security
  Security warning — please read.

  OpenClaw is a hobby project and still in beta. Expect sharp edges.
  By default, OpenClaw is a personal agent: one trusted operator boundary.
  This bot can read files and run actions if tools are enabled.
  A bad prompt can trick it into doing unsafe things.

  OpenClaw is not a hostile multi-tenant boundary by default.
```

Finalmente ya obtendremos OpenClaw y ahora comenzará el proceso de configuración del servicio.

```
• I understand this is personal-by-default and shared/multi-user use requires lock-down. Continue?
  Yes

• Setup mode
  QuickStart

• QuickStart
  Gateway port: 18789
  Gateway bind: Loopback (127.0.0.1)
  Gateway auth: Token (default)
  Tailscale exposure: Off
  Direct to chat channels.
```



Escogeremos el modo de setup en QuickStart (no hay mucho que podamos personalizar de la configuración de momento). Como podemos ver, podemos configurar Tailscale para poder acceder remotamente a openclaw desde el exterior.

Escogemos a Ollama como proveedor de modelos de IA predeterminados.

```
• Model/auth provider
  ◦ Anthropic
  ◦ Arcee AI
  ◦ BytePlus
  ◦ Chutes
  ◦ Cloudflare AI Gateway
  ◦ Copilot Proxy
  ◦ Custom Provider
  ◦ DeepSeek
  ◦ Fireworks
  ◦ Gemini CLI OAuth
  ◦ GitHub Copilot
  ◦ Google
  ◦ Hugging Face
  ◦ Kilo Gateway
  ◦ LiteLLM
  ◦ LM Studio
  ◦ Microsoft Foundry
  ◦ MiniMax
  ◦ Mistral AI
  ◦ Moonshot AI (Kimi K2.5)
  • Ollama (Cloud and local open models)
  ◦ OpenAI
  ◦ OpenAI Codex
  ◦ OpenCode
  ◦ OpenRouter
  ◦ Qianfan
  ◦ Qwen Cloud
  ◦ SGLang
  ◦ StepFun
  ◦ Synthetic
  ◦ Together AI
  ◦ Venice AI
  ◦ Vercel AI Gateway
  ◦ vLLM
  ◦ Volcano Engine
  ◦ xAI (Grok)
  ◦ Xiaomi
  ◦ Z.AI
  ◦ Skip for now
```



Configuramos openclaw para funcionar con Ollama sobre nuestra loopback en el puerto 11434 → <http://127.0.0.1:11434>.

```
◆ Model/auth provider
  Ollama

◆ Ollama base URL
  http://127.0.0.1:11434

◆ Ollama mode
  Local

◆ Default model
  Enter model manually

◆ Default model
  ollama/gemma4
```

NOTA: Probamos a configurar un modelo de IA ollama/gemma4 pero debido a unos problemas con esta IA tuvimos que acabar utilizando un llama3.2b.

No añadiremos canales de momento.

```
◆ Select channel (QuickStart)
  ○ Feishu/Lark (飞书)
  ○ Nostr
  ○ Microsoft Teams (Bot Framework)
  ○ Nextcloud Talk (self-hosted)
  ○ BlueBubbles (macOS app)
  ○ Zalo (Bot API)
  ○ Zalo (Personal Account)
  ○ Discord (Bot API)
  ○ QQ Bot
  ○ WhatsApp (QR link)
  ○ Google Chat (Chat API)
  ○ Mattermost (plugin)
  ○ Matrix (plugin)
  ○ IRC (Server + Nick)
  ○ Synology Chat (Webhook)
  ○ Tlon (Urbit)
  ○ imessage
  ○ LINE (Messaging API)
  ○ signal
  ○ Slack
  ○ telegram
  ○ Twitch (Chat)
  ◆ Skip for now (You can add channels later via `openclaw channels add`)
```



NOVACREUX

Izan Rodríguez
Oscar Toledo

```
iokip@izan-oscar-proyectoasix:~ $ openclaw --version  
OpenClaw 2026.4.14 (323493f)  
iokip@izan-oscar-proyectoasix:~ $
```

Comprobamos que la versión de openclaw sea correcta.




OpenWebUI

Levantamos un docker con el servicio OpenWebUI un servicio que crea una interfaz amigable para el usuario, así que sea mucho más sencillo interactuar con el usuario.

```
iokip@izan-oscar-proyectoasix:~$ docker run -d --network host -v open-webui:/app/backend/data --name open-webui --restart always ghcr.io/open-webui/open-webui:main
Unable to find image 'ghcr.io/open-webui/open-webui:main' locally
main: Pulling from open-webui/open-webui
b084ef52de3a: Pull complete
8a8dcf9df699: Pull complete
9c984a7afc49: Pull complete
43be232c7f10: Pull complete
4f7c4f08ae65: Pull complete
4f4fb708ef54: Pull complete
1a3ad7e7cc1c: Pull complete
1058b1947bb8: Pull complete
7549994be85a: Pull complete
98b5784774ca: Pull complete
9c5ff2729510: Pull complete
80ecd8df1248: Pull complete
313cba756dda: Pull complete
3cc885b9b427: Pull complete
2ee5b4afcb0d: Pull complete
Digest: sha256:b0895f79a6a8ffad8f830bdacc9b5b0aef805689b31bca0b065cc2424d3cfaeb
Status: Downloaded newer image for ghcr.io/open-webui/open-webui:main
9a4b5c83dfee789176ce25d70e18de0d6c337539507cd9798467817ef7bf773b
iokip@izan-oscar-proyectoasix:~$
```

Ya que el proceso es muy similar a hacerlo en otro dispositivo la explicación mas detallada está en la página 46.





Creamos usuarios personales para profesores

ROLE	NAME	EMAIL	LAST ACTIVE	CREATED AT
ADMIN	iokip	iokip@gmail.com	a few seconds ago	14 April 2026
USER	José Dorado	joradot@gesteiverratas.cat	18 minutes ago	14 April 2026
USER	Lluís Ferreres	lferreres@gesteiverratas.cat	15 minutes ago	14 April 2026
USER	Enric Maza	emaza@gestec.cat	15 minutes ago	14 April 2026
USER	generico	generico@gmail.com	a few seconds ago	14 April 2026

Y tras lanzar un prompt revisamos el consumo de hardware, vemos que ollama está en el primer puesto usando mucha CPU, en este momento es en el que nos damos cuenta que no está usando el módulo HAT AI, ya que no es compatible con LLM, no puede generar texto, así que derivamos el proyecto, más adelante se verá.

```
top - 18:54:22 up 2:38, 2 users, load average: 4.21, 2.79, 1.48
Tasks: 239 total, 2 running, 237 sleeping, 0 stopped, 0 zombie
%Cpu(s): 97.6 us, 1.7 sy, 0.0 ni, 0.7 id, 0.0 wa, 0.0 hi, 0.0 si, 0.0 st
MiB Mem : 8058.9 total, 510.7 free, 5087.4 used, 3218.9 buff/cache
MiB Swap: 2048.0 total, 1749.3 free, 298.7 used, 2971.6 avail Mem
```

PID	USER	PR	NI	VIRT	RES	SHR	S	%CPU	%MEM	TIME+	COMMAND
21704	ollama	20	0	4600528	2.4g	25296	S	370.8	30.7	15:49.84	ollama
13331	iokip	20	0	48.7g	129216	57328	R	10.3	1.6	2:01.78	chromium
20643	iokip	20	0	1391.9g	220304	126688	S	5.0	2.7	1:27.80	chromium
1294	iokip	20	0	551376	65024	45584	S	4.3	0.8	1:27.56	labwc
13271	iokip	20	0	48.8g	216448	145680	S	3.0	2.6	1:05.16	chromium
3591	vnc	20	0	736000	31088	19968	S	0.7	0.4	4:28.80	wayvnc
18175	root	20	0	4213648	998.3m	180704	S	0.7	12.4	0:58.08	python3
18	root	20	0	0	0	0	I	0.3	0.0	0:02.75	rcu_pre+
709	avahi	20	0	6032	3408	2784	S	0.3	0.0	0:00.47	avahi-d+
2960	root	20	0	343056	14240	11648	S	0.3	0.2	0:03.88	Network+
12506	iokip	20	0	582896	60480	38160	S	0.3	0.7	2:17.46	x-termi+
21137	root	20	0	0	0	0	I	0.3	0.0	0:01.32	kworker+
21514	root	20	0	0	0	0	I	0.3	0.0	0:00.92	kworker+
22593	root	20	0	0	0	0	I	0.3	0.0	0:00.54	kworker+
1	root	20	0	25920	11936	7872	S	0.0	0.1	0:04.67	systemd
2	root	20	0	0	0	0	S	0.0	0.0	0:00.01	kthreadd
3	root	20	0	0	0	0	S	0.0	0.0	0:00.00	pool wo+



Analizador Video AI

Instalamos los drivers del módulo HAT AI2+ para que el hardware se pueda comunicar

```
iokip@izan-oscar-proyectoasix:~$ sudo apt install hailo-h10-all -y
hailo-h10-all is already the newest version (5.1.1).
Summary:
  Upgrading: 0, Installing: 0, Removing: 0, Not Upgrading: 0
```

Creamos un directorio de trabajo, aquí es donde trabajaremos con toda la IA, además iniciaremos un entorno seguro (venv), entraremos en el entorno.

```
iokip@izan-oscar-proyectoasix:~$ mkdir narrador_ia && cd narrador_ia
iokip@izan-oscar-proyectoasix:~/narrador_ia$ python3 -m venv venv
iokip@izan-oscar-proyectoasix:~/narrador_ia$ source venv/bin/activate
(venv) iokip@izan-oscar-proyectoasix:~/narrador_ia$
```

No solo necesitaremos los drivers para la HAT, también necesitaremos algunas librerías de python.

- Gradio: sirve para crear una interfaz web interactiva (Al final no lo usamos)
- OpenCV-Python: Procesa imágenes y videos en tiempo real (sirve especialmente para procesar imágenes y videos en tiempo real, normalmente se usa para cámaras en tiempo real, aunque también procesa la de videos).
- hailo-python-api: Sirve para comunicar el script python que crearemos con el chip Hailo.

```
(venv) iokip@izan-oscar-proyectoasix:~/narrador_ia$ pip install --default-timeout=1000 --retries 10 gradio opencv-python hailo-python-api
Looking in indexes: https://pypi.org/simple, https://www.piwheels.org/simple
Collecting gradio
  Downloading https://www.piwheels.org/simple/gradio/gradio-6.12.0-py3-none-any.whl (19.6 MB)
    ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 19.6/19.6 MB 8.6 MB/s eta 0:00:00
Collecting opencv-python
  Downloading opencv_python-4.13.0.92-cp37-abi3-manylinux_2_28_aarch64.whl.metadata (19 kB)
```



Descargamos 2 modelos similares desde la web, aunque sea una manera de hacerlo, nosotros al final hemos descartado este método, por uno el cual ya aplica el modelo

Technical Details

Image Input Size:	[288, 512, 3]
Numerical Scheme:	A16W4, symmetric, group-wise
Inference Api:	C++, Python
Vision Tokens Per Frame:	144
Context Length:	2048
Compiled Model:	Download

Performance Metrics



Ya vemos uno de los modelos descargados, el Qwen3

```
iokip@izan-oscar-proyectoasix:~/narrador_ia $ ls -la
total 3111128
drwxrwxr-x  3 iokip iokip    4096 Apr 20 19:25 .
drwx----- 15 iokip iokip    4096 Apr 20 18:57 ..
-rw-rw-r--  1 iokip iokip    3442 Apr 20 19:27 hailort.log
-rw-rw-r--  1 iokip iokip 3185773502 Apr 20 19:24 Qwen3-VL-2B-Instruct.hef
drwxrwxr-x  5 iokip iokip    4096 Apr 20 18:44 venv
iokip@izan-oscar-proyectoasix:~/narrador_ia $
```

Al final inyectamos el modelo por otro método el cual nos permite saltarnos unos pasos, es el más usado y el estándar, usar el comando *ollama pull (modelo a elegir)*

```
iokip@izan-oscar-proyectoasix:~/narrador_ia $ ollama pull qwen3-vl
pulling manifest
pulling ed12a4674d72: 100% [REDACTED] 6.1 GB
pulling 7339fa418c9a: 100% [REDACTED] 11 KB
pulling f6417cb1e269: 100% [REDACTED] 42 B
pulling 17e666f4e4f4: 100% [REDACTED] 551 B
verifying sha256 digest
writing manifest
success
iokip@izan-oscar-proyectoasix:~/narrador_ia $
```

Vemos el modelo listado

```
iokip@izan-oscar-proyectoasix:~/narrador_ia $ ollama list
NAME                ID                SIZE      MODIFIED
qwen3-vl:latest     901cae732162     6.1 GB    About a minute ago
llama3.2:1b         baf6a787fdff     1.3 GB    6 days ago
iokip@izan-oscar-proyectoasix:~/narrador_ia $
```

Ejecutamos el modelo usando el siguiente comando

```
iokip@izan-oscar-proyectoasix:~/narrador_ia $ hailo-ollama run Qwen3-VL-2B-Instruct.hef
I | 2026-04-20 19:36:38 1776706598796947| MyApp:Server running on port 8000
```

Lo vemos ejecutándose





A continuación en nuestro directorio de trabajo creamos un fichero .py , tras la explicación del código está el código usado.

El programa utiliza las librerías OpenCV, Ollama y OS para realizar una consulta de visión artificial. Primero configura la variable de entorno OLLAMA_HOST para conectar el cliente de Python con el servidor local del chip Hailo en el puerto 8000.

Define el modelo qwen3-vl:latest y el archivo de video traffic.mp4.

Dentro de la función procesar_video() se abre el video, se extrae un fotograma del segundo 1, se redimensiona a 640×480 píxeles y se guarda como frame_ia.jpg.

Luego se envía esa imagen al modelo Qwen3-VL (VL es el tipo de IA especializada en análisis de imágenes) con una instrucción textual para que describa los objetos y la acción principal del video.

El modelo devuelve una narración del contenido visual, que se muestra en pantalla.

Si ocurre algún error de comunicación, se imprime el mensaje correspondiente.

Finalmente, el script ejecuta la función procesar_video() cuando se lanza directamente.

```
import cv2
import ollama
import os
os.environ["OLLAMA_HOST"] = "http://localhost:8000"
MODELO = "qwen3-vl:latest"
VIDEO_PATH = "traffic.mp4"
def procesar_video():
    cap = cv2.VideoCapture(VIDEO_PATH)
    if not cap.isOpened():
        print(f"? Error: No se encuentra el archivo {VIDEO_PATH}")
        return
    fps = cap.get(cv2.CAP_PROP_FPS)
    cap.set(cv2.CAP_PROP_POS_MSEC, 1000)
    ret, frame = cap.read()
    cap.release()
    if ret:
        frame = cv2.resize(frame, (640, 480))
        cv2.imwrite("frame_ia.jpg", frame)
        print(f"?? Consultando a Qwen3-VL sobre {VIDEO_PATH}...")
        try:
            res = ollama.chat(
                model=MODELO,
                messages=[{
                    'role': 'user',
                    'content': 'Que ves en este video? Describe los objetos y la accion principal.',
                    'images': ['frame_ia.jpg']
                }]
            )
            print("\n? NARRACION DE LA IA:")
            print(res['message']['content'])
        except Exception as e:
            print(f"? Error en la comunicación con el chip: {e}")
if __name__ == "__main__":
    procesar_video()
```




Captura de pantalla del código python

```
(venv) iokip@izan-oscar-proyectoasix:~/narrador_ia $ cat analizador_video.py
import cv2
import ollama
import os

# Forzamos a que el cliente de Python mire al puerto de Hailo
os.environ["OLLAMA_HOST"] = "http://localhost:8000"

MODELO = "qwen3-vl:latest"
VIDEO_PATH = "traffic.mp4"

def procesar_video():
    cap = cv2.VideoCapture(VIDEO_PATH)
    if not cap.isOpened():
        print(f"? Error: No se encuentra el archivo {VIDEO_PATH}")
        return

    fps = cap.get(cv2.CAP_PROP_FPS)

    # Sacamos un frame del segundo 1
    cap.set(cv2.CAP_PROP_POS_MSEC, 1000)
    ret, frame = cap.read()
    cap.release()

    if ret:
        # Redimensionamos para que el chip vuele (40 TOPS!)
        frame = cv2.resize(frame, (640, 480))
        cv2.imwrite("frame_ia.jpg", frame)

        print(f"?? Consultando a Qwen3-VL sobre {VIDEO_PATH}...")

        try:
            res = ollama.chat(
                model=MODELO,
                messages=[{
                    'role': 'user',
                    'content': 'Que ves en este video? Describe los objetos y la
accion principal.',
                    'images': ['frame_ia.jpg']
                }]
            )
            print("\n? NARRACION DE LA IA:")
            print(res['message']['content'])
        except Exception as e:
            print(f"? Error en la comunicacion con el chip: {e}")

if __name__ == "__main__":
    procesar_video()
```




En el código aparece que estaremos analizando el video traffic.mp4, se puede ver el video en el siguiente enlace a drive [📁 traffic.mp4](#) .

Después ejecutaremos el código en cuestión y lo comenzará a analizar frame por frame, este proceso por el tipo de hardware que tenemos a nuestro abasto es bastante largo, alrededor de 15min, a partir de esto se pueden hacer miles de cosas con uso real, por ejemplo:

- Si detectamos que un trabajador no lleva casco llama o notifica a...
- Si ves mucha gente notifica de otra salida
- Si ves un accidente crea una alerta para los conductores o cierta institución responsable
- Si ves humo lanza alerta de incendio

Y una larga lista de posibilidades



RESPUESTA FINAL IA

? NARRACION DE LA IA:

En el video se observa una ****carretera elevada o autopista**** con múltiples carriles marcados por líneas blancas discontinuas. Los elementos principales son:

- ****Carretera****: Amplia, de asfalto oscuro, con carriles bien definidos y una superficie que muestra algunas grietas o imperfecciones.
- ****Vehículo****: Un ****SUV blanco**** circula en el carril derecho de la autopista, moviéndose hacia el frente (aparentemente en dirección descendente por el ángulo de la cámara).
- ****Estructuras adyacentes****:
 - A la izquierda, una ****baranda de concreto**** que forma parte de la estructura de la autopista, junto a un sendero peatonal o plataforma lateral.
 - A la derecha, una ****valla metálica**** que separa la carretera de una ****vía férrea**** (con rieles y grava a los lados), y un ****andén**** donde se ven algunas personas de pie (en el extremo derecho del recuadro).

La acción principal es el ****movimiento del SUV**** por la autopista, mientras el entorno muestra una infraestructura urbana que combina vía rápida, transporte ferroviario y espacios para peatones.

NARRACION DE LA IA:

En el video se observa una ****carretera elevada o autopista**** con múltiples carriles marcados por líneas blancas discontinuas. Los elementos principales son:

- ****Carretera****: Amplia, de asfalto oscuro, con carriles bien definidos y una superficie que muestra algunas grietas o imperfecciones.
- ****Vehículo****: Un ****SUV blanco**** circula en el carril derecho de la autopista, moviéndose hacia el frente (aparentemente en dirección descendente por el ángulo de la cámara).
- ****Estructuras adyacentes****:
 - A la izquierda, una ****baranda de concreto**** que forma parte de la estructura de la autopista, junto a un sendero peatonal o plataforma lateral.
 - A la derecha, una ****valla metálica**** que separa la carretera de una ****vía férrea**** (con rieles y grava a los lados), y un ****andén**** donde se ven algunas personas de pie (en el extremo derecho del recuadro).

La acción principal es el ****movimiento del SUV**** por la autopista, mientras el entorno muestra una infraestructura urbana que combina vía rápida, transporte ferroviario y espacios para peatones.



NVIDIA SPARK

SPARK combina varias GPU de arquitectura Blackwell (la más reciente de NVIDIA) en un sistema compacto y escalable. Está diseñado como un superordenador personal o de laboratorio, capaz de ejecutar tareas que antes requerían centros de datos enteros.

Su propósito principal es entrenar y ejecutar modelos de IA de gran tamaño.

También se usa para:

- Simulaciones científicas y análisis de datos masivos.
- Renderizado 3D y generación de contenido con IA.
- Desarrollo de modelos multimodales (texto, imagen, audio, vídeo).
- Investigación en IA generativa y aprendizaje automático.

	Especificación
GPU	Blackwell
Memoria RAM	48–96GB hasta 128GB
Almacenamiento	NVME hasta 60TB
Consumo	100W - 240W
Capacidad de IA en B	70B - 400B en rac




Agradecemos a Enric Mieza por dejarnos acceso al hardware Nvidia Spark a través de una máquina virtual.



Instalación de OpenWebUI

Ya que desde la máquina virtual no tenemos acceso directo a ollama y este esta montado en la NVIDIA Spark no es necesaria la instalación de ollama, este paso se ha realizado anteriormente, nosotros prepararemos el frontend, la parte visual conectada al Ollama la cual permite al usuario interactuar con esta.

Cada mensaje o interacción con la IA realiza el siguiente camino:



Comenzaremos actualizando los repositorios y posteriormente instalaremos docker.io

```
super@pitia:~$ sudo apt install docker.io
S'està llegint la llista de paquets... Fet
S'està construint l'arbre de dependències... Fet
S'està llegint la informació de l'estat... Fet
S'instal·laran els següents paquets extres:
  bridge-utils containerd dns-root-data dnsmasq-base git git-man liberror-perl libgdbm-compat4 libperl5.34 patch perl
  perl-base perl-modules-5.34 pigz runc ubuntu-fan
Paquets suggerits:
```

Le daremos los permisos necesarios a nuestro usuarios para poder ejecutar comandos de docker

```
super@pitia:~$ sudo usermod -aG docker $USER
super@pitia:~$
```

Ahora lanzaremos nuestro contenedor de OpenWebUI en el puerto Web el 80

```
super@pitia:~$ sudo docker run -d -p 80:8080 -v open-webui:/app/backend/data --name open-webui ghcr.io/open-webui/open-webui:main
9c0ef887b55204cd1d55de72e67dafbeea982d5ce13e6c6984c32e6f38010792
```



Una vez ejecutado con el comando `docker ps` podemos ver que este esta correctamente en marcha

```
super@pitia:~$ docker ps
```

CONTAINER ID	IMAGE	NAMES	COMMAND	CREATED	STATUS	PORTS
9c0ef887b552	ghcr.io/open-webui/open-webui:main	open-webui	"bash start.sh"	About a minute ago	Up About a minute (healthy)	0.0.0.0:80->8080/tcp, [::]:80->8080/tcp

Pasamos a comprobar que el entorno web de OpenWebUI está correcto descargando la página web de OpenWebUI, podremos ver al completo el código HTML de OpenWebUI, al ser un proyecto abierto este nos permite si es de nuestro agrado modificar a nuestro gusto el entorno visual.

```
super@pitia:~$ curl localhost
<!doctype html>
<html lang="en">
  <head>
    <meta charset="utf-8" />
    <link rel="icon" type="image/png" href="/static/favicon.png" crossorigin="use-credentials" />
    <link
      rel="icon"
      type="image/png"
      href="/static/favicon-96x96.png"
      sizes="96x96"
      crossorigin="use-credentials"
```


Posteriormente la persona con acceso a la NVIDIA Spark realiza un pull del modelo que queremos que nuestra IA ejecute, antes de realizar este paso tendremos que probar y informarnos sobre hasta cuantos b (billones de parametros) nuestro hardware puede ejecutar, en nuestro caso probamos uno de 70b y 72b, ambos corren perfectamente, pero al realizar la misma operación con uno de 128b y enviar un solo prompt este sobrepasaba la memoria de la que dispone el hardware y bloqueaba Ollama

```
super@pitia:~$ ollama pull llama3:70b
pulling manifest
pulling 0bd51f8f0c97: 100%
pulling 4fa551d4f938: 100%
pulling 8ab4849b038c: 100%
pulling 577073ffcc6c: 100%
pulling ea8e06d28e47: 100%
verifying sha256 digest
writing manifest
success
super@pitia:~$
```

```
super@pitia:~$ ollama pull mistral-medium-3.5:128b
pulling manifest
pulling f68f582c8d0c: 100%
pulling 20c887c0de3e: 100%
pulling a11f7cb278dd: 100%
pulling c5785e3e97ac: 100%
verifying sha256 digest
writing manifest
success
super@pitia:~$
```




Ahora podemos buscar en internet el dominio o IP y puerto relacionado con nuestro servicio OpenWebUI y accederemos a este con un nuevo usuario y contraseña.




Antes de realizar cualquier pregunta, en la parte superior donde seleccionamos los modelos nos dirá “selecciona modelo”, eso significa que aún no ha conectado con la NVIDIA Spark, para conectarlo seguimos estos pasos.

Accedemos a ajustes de Administración






En el panel de administración entramos en Conexiones



En medio veremos una conexión que se llama docker, esta la debemos apagar usando el switch de la derecha, buscaremos el + cercano y crearemos la conexión, pondremos la IP de la NVIDIA SPARK y el puerto 11434, ya que es hardware en gestión de Enric Mieza hemos decidido censurar la IP de este por seguridad.



Ahora si tendremos toda la configuración lista para poder usar nuestra IA en local con un superordenador personal. Para poder acceder entraremos a la web pitia.ieti.site



Framework AI starter Kit for Jetson Orin Nano

Este es un kit educativo y de desarrollo para aprender sobre toda la inteligencia artificial, este maletín contiene una gran variedad de elementos I/O para poder usar la IA, este kit es muy interesante ya que se puede programar o adaptar la inteligencia para el uso de todos estos elementos de manera autónoma, podemos poner a prueba de una mejor maneras ideas como notificar si la cámara con servos y abatible detecta humo o otros muchos ejemplos, contiene sensores muy variados que se explicaran de manera breve posteriormente.






El kit maletín, si observamos todos los elementos I/O vemos los siguientes:





Nvidia Jetson Orin Nano

La Nvidia Jetson Orin Nano requiere de un sistema operativo para funcionar, el cual no viene incluido de serie en el disco. Por lo tanto, haremos un paso a paso de como instalar dicho sistema operativo sobre este sistema.






Primeramente deberemos tener a mano un disco MicroSD de mínimo 64GB de capacidad. En nuestro caso utilizaremos una MicroSD de 512GB.


Paso 1: Descargar JetPack.


- JetPack es el sistema operativo de Jetson Orin. Para poder instalar dicho sistema en nuestra Jetson Orin Nano deberemos descargar de esta [web](#) la imagen para discos SD de JetPack 6.2 (qué es la más reciente para este sistema).

Paso 2: Flashear la tarjeta SD.


- Utilizaremos BalenaEtcher o algún programa similar (como Rufus) para flashear la SD e insertar en ella el sistema operativo.









Insertamos en la placa de la Jetson Orin la tarjeta SD en la ranura que encontraremos en el lateral derecho de la Jetson Orin



Nota de uso: Podemos utilizar un software como BalenaEtcher o RaspberryPi Imager para poder flashear el disco duro sin problema, sin embargo, tenemos el software de SDK Manager de Nvidia. Es una manera más visual de poder instalar directamente el sistema operativo sobre nuestro dispositivo. Para utilizar el software deberemos conectar el disco sd sin el sistema, conectar por USB-C el ordenador a la Jetson Orin, escoger el hardware, la versión del sistema operativo (el máximo permitido por la Jetson Orin Nano es la versión 6.2.2). Además podemos añadir diferentes SDKs extra.



Una vez conectamos el disco y encendemos la Jetson, veremos el “GRUB” personalizado de NVIDIA, aquí abriremos la configuración de la BIOS con la tecla ESC.



Abrimos la BIOS y accedemos al Boot Manager para poder acceder al sistema operativo utilizando la entrada del disco SD.



Comparación entre Hardwares

Tabla de comparación

	Nvidia 4060 Ti 16GB	Raspberry Pi HAT2+	Nvidia Spark
Arquitectura	Ada Lovelace	ARM Cortex-A76 + NPU Hailo-8	Blackwell
VRAM	16GB GDDR6	8GB LPDDR4 (RAM) + 26 TOPS NPU	48-96GB hasta 128GB
TPD	165W	5W – 12W	100W - 240W
Uso Típico	IA Local, modelos de hasta 24B en VRAM, Gaming	Edge AI, visión artificial, IoT, inferencia ligera	Entrenamiento, inferencia, modelos de 70B - 400B
Ventaja	Coste "Bajo", accesible, Baja latencia	Ultra bajo consumo, ideal para IA embebida, muy portátil	Escalabilidad buena, paralelización, gran memoria
Limitaciones	VRAM Limitada, no apta para modelo grandes	No apto para modelos grandes, potencia limitada	Coste, consumo, Complejidad



NVIDIA 4060 Ti 16GB

Esta gráfica pertenece a la gama de consumo de NVIDIA, basada en la arquitectura ADA Lovelace, ofrece un rendimiento y eficiencia muy buena para IA en local y gaming (hasta 24B parámetros), ofrece una ventaja el coste es accesible y tiene una baja latencia, lo que la hace buena para un usuario que quiera jugar y estudiante que quieran experimentar con la IA, pero su mayor limitación es la VRAM, aunque tenga 16GB se queda corta.



Raspberry Pi HAT AI2+



Este dispositivo combina un procesador ARM Cortex-A76 con una NPU Hailo-8, capaz de alcanzar 26 TOPS. Está pensado para IA embebida, visión artificial y IoT, donde se necesita inferencia rápida con muy bajo consumo energético (5–12 W)

Su principal ventaja es la portabilidad y la eficiencia energética, ideal para proyectos de campo o dispositivos inteligentes. Tiene una limitación muy clara: no puede ejecutar modelos grandes; su potencia está enfocada a tareas ligeras y específicas.




NVIDIA SPARK

SPARK representa el nivel profesional y de investigación. Usa arquitectura Blackwell, con hasta 128 GB de memoria HBM3e y potencia suficiente para manejar modelos de 70 B a 400 B parámetros. Está diseñado para entrenamiento intensivo, inferencia avanzada y IA generativa multimodal (texto, imagen, audio). Su ventaja es la escalabilidad y la paralelización masiva, pero su coste y consumo lo hacen adecuado sólo para entornos empresariales o académicos.



NVIDIA JETSON ORIN NANO



Este hardware representa el nivel de Edge AI y Robótica. Está basada en la arquitectura Ampere, diseñada para ejecutar IA directamente sobre otros dispositivos (drones, cámaras o robots y dispositivos IoT). Tiene un rendimiento de 40 TOPS, con un consumo muy ajustado de 7 a 15W. Su capacidad para

realizar procesamiento en tiempo real está en el borde para no depender de la nube y tiene la ventaja de la compatibilidad del ecosistema JetPack y sus ventajas. Su limitación es la potencia bruta comparada a GPU de escritorio y su poca memoria compartida de 8GB, puede con modelos de 1 a 7B de parámetros.



Consumos de energía y tokens

Muchos de los servicios e ideas presentadas en el proyecto suelen estar hospedadas y encendidas 24/7 por lo que el consumo tanto de energía como de esfuerzo por segundo del hardware (tokens) es importante de medir antes de realizar una compra y poner en producción, por lo que hemos hecho algunos cálculos aproximados, con consumos y precios medios para saber qué es lo que más conviene tener en cuanto a gastos.

	Consumo medio (W)	Coste aproximado por año (€)	Tokens por segundo, depende de modelo
Homelab Server	~6W	12€	X
PC IA en local 4060 TI 16Gb	~150W	130€	12 - 18 Tokens/s (24B)
Raspberry Pi 5 + AI HAT	~12W	10€	3 - 5 tokens/s (3B)
NVIDIA Jetson Orin Nano	~15W	13€	10 - 15 Tokens/s
NVIDIA Spark	~10W	12€	15 - 22 Tokens/s

Nota: El PC de IA varía drásticamente según si la GPU está en reposo o procesando un modelo a plena carga.



3 Tipos de RAM y Crisis

Para el desarrollo de este punto, tipos de RAM y crisis, como parte de las pruebas de la IA en local, usando como motor la NVIDIA Spark y el modelo llama de 70b hemos extraído la siguiente información, hemos revisado que la información proporcionada por la IA es real y lógica, además de adaptarla ligeramente por nosotros.

1. DDR (Double Data Rate)

- Utiliza una señal de reloj para transferir datos en dos momentos: al subir y bajar la señal de reloj.
- Los datos se transmiten en ambos flancos del ciclo de reloj, lo que duplica la velocidad de transferencia.
- DDR es una tecnología más antigua, pero sigue siendo común en muchos dispositivos electrónicos.

2. GDDR (Graphics Double Data Rate)

- Es un tipo de memoria RAM diseñada específicamente para tarjetas gráficas y aplicaciones que requieren altas velocidades de transferencia.
- Ofrece una mayor velocidad y ancho de banda que la DDR estándar, lo que permite manejar grandes cantidades de datos en aplicaciones gráficas intensivas.
- GDDR es más rápida y eficiente en cuanto al consumo de energía que la DDR.

3. HBM (High-Bandwidth Memory)

- Es una tecnología de memoria RAM diseñada para aplicaciones que requieren muy altas velocidades de transferencia, como tarjetas gráficas de alta gama y procesadores de aprendizaje automático.
- Utiliza un diseño de memoria en 3D, donde varios niveles de memoria se apilan uno encima del otro, lo que permite una mayor densidad y velocidad.
- HBM es la tecnología más rápida y eficiente en cuanto al consumo de energía de las tres, pero también es la más cara y compleja.

En resumen:

DDR es una tecnología más antigua y común, adecuada para aplicaciones generales.

GDDR es una variante de DDR diseñada específicamente para aplicaciones gráficas intensivas.

HBM es la tecnología más rápida y eficiente, pero también la más cara y compleja, utilizada en aplicaciones que requieren muy altas velocidades de transferencia.




NOVACREUX


Izan Rodríguez
Oscar Toledo



Memoria DDR



Memoria HBM



Memoria GDDR




La crisis de la RAM a fecha de hoy 2025/2026 se debe a varios factores que han hecho que haya un gran desequilibrio entre la oferta y la demanda, lo que ha provocado una subida de precio muy elevado en las memorias RAM:

1. **Crecimiento explosivo de la demanda:** El crecimiento del mercado de la Inteligencia Artificial y el IoT ha generado una gran demanda de RAM de alta velocidad y baja latencia y la adopción masiva de tecnología como 5G, edge computing, cloud gaming también ha aumentado la demanda de RAM.
2. **Disminución de la oferta:** Debido a la pandemia COVID-19 la industria de la RAM enfrentó una serie de desafíos que afectaron a la producción y distribución de componentes, también la escasez global de chips de silicio y otras materias críticas ha limitado la capacidad de que los fabricantes produzcan la cantidad de RAM demandada.

Entre otras muchas razones que han colaborado en la crisis actual

DDR5-4800 2x16GB (Average price in USD over last 18 months)





Ingeniería de Prompt

La ingeniería de prompt se define como el proceso de diseñar, refinar y optimizar las instrucciones (prompts) proporcionadas a los modelos LLM para obtener respuestas precisas, coherentes y de alta calidad. A diferencia de la programación tradicional, que se basa en código rígido, la ingeniería de prompt utiliza lenguaje natural como interfaz. Su principal objetivo es cerrar la brecha entre la intención del usuario y la capacidad de procesamiento del modelo, minimizando las alucinaciones y maximizando la relevancia del resultado.

Para que una interacción con un LLM sea exitosa, debemos generar un prompt estructurado que incluya los siguientes elementos:

- **Instrucciones:** Una tarea específica que se desea que el modelo realice (Ejemplo: Resume, Clasifica, Escribe código...)
- **Contexto:** Información externa o de fondo que guía al modelo para situarse en el escenario adecuado (Ej: Actúa como un experto en ciberseguridad...).
- **Datos de entrada:** La información específica que el modelo debe procesar.
- **Indicadores de salida:** Especificaciones sobre el formato, tono o longitud de la respuesta (ej. Genera una tabla, Usa un tono formal, Máximo 200 palabras...etc).

Durante el desarrollo de este proyecto, se han aplicado diversas técnicas avanzadas de ingeniería de prompts para mejorar el rendimiento del sistema y las respuestas de nuestras pruebas con LLMs:

1. **Zero-Shot Prompting:** Se le pide al modelo que realice una tarea sin proporcionar ejemplos previos, confiando enteramente en su entrenamiento base.
2. **Few-Shot Prompting:** Se incluyen algunos ejemplos de pares (entrada/salida) dentro del prompt para que el modelo aprenda el patrón o formato deseado antes de generar la respuesta final.
3. **Chain-of-Thought (CoT):** Se induce al modelo a "pensar en voz alta", desglosando problemas complejos en pasos lógicos intermedios. Esto reduce significativamente los errores de razonamiento en tareas matemáticas o de análisis profundo.
4. **Prompt Acting (Asignación de Rol):** Técnica donde se define una personalidad o perfil profesional para el modelo, lo que ajusta su vocabulario y perspectiva técnica.



	Zero-Shot	Instrucción directa sin proveer ejemplos previos.
	Few-Shot	Incluir 2 a 3 ejemplos precisos del resultado esperado directamente dentro del prompt.
	Chain-of-Thought (Cadena de Pensamiento)	Obligar a la IA a escribir sus pasos de razonamiento lógico explícitamente antes de dar la respuesta final.

Ejemplo de prompt perfecto:

Instrucción: Explica la diferencia técnica entre un modelo de lenguaje "Base" (Pre-trained) y un modelo "Instruido" (Instruction-tuned).

Contexto: Estoy preparando una presentación para desarrolladores junior que ya entienden qué es una red neuronal, pero no comprenden por qué no pueden usar un modelo base directamente en un chatbot.

Puntos clave a cubrir:

1. El objetivo del entrenamiento de un modelo Base (predicción del siguiente token).
2. El proceso de RLHF (Aprendizaje por Refuerzo a partir de Retroalimentación Humana) en los modelos instruidos.
3. Un ejemplo de cómo respondería cada modelo a la pregunta "¿Cuál es la capital de Francia?".



Restricciones:

- Usa un tono técnico pero didáctico.
- No utilices más de 300 palabras.
- Evita analogías excesivamente simples; prefiere precisión técnica.

Formato de salida:

- Definición breve de ambos.
- Lista comparativa de características.
- Ejemplo de respuesta (Base vs. Instruido).

Ejemplo de mal prompt:

Prompt: "Compara el modelo GPT-4o con Claude 3.5 Sonnet y dime cuál es mejor para programar. Hazlo detallado."



Partes no completadas y Expansiones

Para la planificación del proyecto hemos decidido ser muy ambiciosos, teniendo en sobreestima nuestra capacidad para el tiempo del que hemos dispuesto, que este año ha sido muy recortado frente a años anteriores. Queremos destacar que aún con la ambición del proyecto hemos sabido organizarlo, ya que se ha repartido en varios bloques relativamente independientes que podíamos gestionar y abrir, cerrar y finalizar sin afectar a otros puntos del proyecto.

Ha habido varias cosas en nuestro proyecto que por prioridad hemos tenido que no completar o dejar de priorizar por lo que para la fecha de presentación no está presente.

En el apartado de la raspberry no hemos podido completar que el análisis de video se realice in situ, con imágenes en directo provenientes de una cámara funcionando al mismo tiempo que la IA de reconocimiento de imágenes, debido a la falta también de tiempo hemos dejado de lado añadirle baterías y el módulo GPS, el cual podría haber sido una pieza de juego bastante importante, además de el uso decente de una IA LLM generativa de texto usando el módulo HAT de la raspberry no ha sido posible, ya que la HAT no tiene potencia suficiente y no existen drivers y software que permita que sea buena la experiencia de usarla.

En el apartado del homelab por falta de presupuesto personal, no hemos podido realizar un NAS con una configuración decente, ya que no disponemos de discos suficientes para esta función.

Siendo un proyecto grande y con muchos puntos siempre nos hemos planteado como añadir nuevos puntos al proyecto, como mejorarlo y que podría ser de utilidad, por lo que al momento de la planificación del preproyecto se ha puesto sobre la mesa muchos más temas relacionados, entre ellos están los siguientes:

- Chatbot local en la raspberry usando el móvil con Whatsapp, telegram como medio de conexión entre usuario y IA, implementando un LLM y flujos de trabajo propios hechos desde n8n.
- Automatizaciones de procesos existentes usando la plataforma n8n.
- Integración total en un mismo ecosistema, mediante una misma red, usando VPN Wireguard o similar, creando un ecosistema conectado entre todos.
- Parte de la documentación del apartado de raspberry es sobre OpenClaw un sistema que permite que un modelo de IA realice cambios sobre su entorno, modificaciones de archivos, acceso a dispositivos IoT, implementación de servicios, todo con prompts de texto o voz, se podría implementar el sistema para crear un asistente chatbot para realizar tareas.



Conclusiones

Durante el desarrollo del proyecto hemos podido aprender una gran variedad de herramientas punteras, las cuales no todas son posibles trabajarlas en clase, por lo menos ahora, y hemos sacado muchos conocimientos que muy posiblemente se apliquen de manera extendida dentro de poco tiempo en muchos ámbitos con todo el auge de la IA, ya que pensamos que la IA no es pasajera, sino se convertirá en una herramienta más que se usará a diario y se irá perfeccionando y especializando para cada caso.

Queremos recalcar que todo el proyecto se ha realizado en un periodo de tiempo bastante reducido y con plazos pactados entre los dos ajustados, aunque este haya sido suficiente para presentar un proyecto bastante grande nos hemos tenido que dejar de lado algunos puntos los cuales nos hubiera gustado hacer, que en el punto anterior lo aclaramos.

En este proyecto hemos visto muchas tecnologías de vanguardia y como las usadas, aún no se están usando realmente en empresas, por lo que existe un nicho de mercado por el cual se puede crecer como una nueva empresa.

Además queremos y creemos que este proyecto sea una declaración de intenciones y un punto importante donde promocionarnos y dar a demostrar nuestras capacidades.



Web/Bibliografía

[Tailscale](#) - VPN basada en wireguard

[Uptime Kuma](#) - Página oficial de Uptime Kuma, instrucciones de instalación.

[Netdata](#) - Página oficial de NetData, instrucciones de instalación.

[Immich](#) - Página oficial de Immich, instrucciones de instalación, uso y aplicaciones cliente de móvil

[Ollama](#) - Página oficial de Ollama, instrucciones variadas, repositorio amplio de modelos disponibles

[Open-webui](#) - Página oficial de Open WebUI, instalación de entorno cliente de IA

[Qwen3-VL](#) : Página con modelos IA descargables

[skool Claude Code](#) - Enlace a curso gratuito de Inteligencia Artificial en el que se explica cómo podemos configurar Claude Code en local y realizar conexiones con aplicaciones y skills.

[Skool Skills Claude Code](#) - Enlace a curso gratuito de Inteligencia Artificial en el que se explica cómo podemos configurar Claude Code en local y realizar conexiones con aplicaciones y skills.

[elecrow Manual](#) - Información básica del framework

[NVIDIA](#) - Pagina de NVIDIA

[NVIDIA JetPack Archive](#) - Repositorio de versiones del sistema operativo de Nvidia.

[Xataka Tokens](#) - Explicación sobre el término Tokens



NOVACREUX

Izan Rodríguez
Oscar Toledo